

中国科学院大学
University of Chinese Academy of Sciences

硕士学位论文

面向网络流量的重复音视频文件实时检测系统研究

作者姓名：陈冠林

指导教师：刘庆云 正高级工程师

中国科学院信息工程研究所

学位类别：工程硕士

学科专业：计算机技术

培养单位：中国科学院信息工程研究所

2019 年 6 月

Research on Real-time Detection System of Repeated Audio and Video Files for Network Traffic

A thesis submitted to the
University of Chinese Academy of Sciences
in partial fulfillment of the requirement
for the degree of
Master of Engineering
in Computer Technology

By

Chen Guanlin

Supervisor: Professor Liu Qingyun

Institute of Information Engineering, Chinese Academy of Sciences

June, 2019

中国科学院大学
学位论文原创性声明

本人郑重声明：所呈交的学位论文是本人在导师的指导下独立进行研究工作所取得的成果。尽我所知，除文中已经注明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的研究成果。对论文所涉及的研究工作做出贡献的其他个人和集体，均已在文中以明确方式标明或致谢。本人完全意识到本声明的法律结果由本人承担。

作者签名：

日　　期：

中国科学院大学
学位论文授权使用声明

本人完全了解并同意遵守中国科学院大学有关保存和使用学位论文的规定，即中国科学院大学有权保留送交学位论文的副本，允许该论文被查阅，可以按照学术研究公开原则和保护知识产权的原则公布该论文的全部或部分内容，可以采用影印、缩印或其他复制手段保存、汇编本学位论文。

涉密及延迟公开的学位论文在解密或延迟期后适用本声明。

作者签名：　　导师签名：

日　　期：　　日　　期：

摘 要

随着互联网的发展，网络已经渗入到我们生活的方方面面，越来越多的人使用网络观看和下载音视频节目，这也使得音视频流量已经成为网络流量中占比最高的部分。根据 sandvine 发布的 2018 年全球互联网观察显示，视频流量已经占据全球流量的 57.69%，较去年增长了 22.43%。

可见，大量的音视频文件通过网络进行传输，这些音视频流量中存在重复，而代理服务器、入侵检测系统等网络中间件需要对这些流量处理，以达到版权保护、色情检测等目的。但对这些网络中间件对于重复流量的处理消耗了大量资源。为此，本文构建了一套实时的重复音视频文件检测系统，该系统可以对网络流量中的重复音视频内容进行检测，用以指导网络中间件的处理，最终达到节约网络、存储和计算资源的目的。

整个系统主要基于以下两个技术：1）预测性文件标识生成方法。该技术采用信息熵和互信息作为评价标准，对生成文件标识的特征进行筛选，并在流量建立连接时，生成一个具有预测性的文件标识。2）基于流式模糊哈希的重复音视频检测方法。若文件标识在数据库中可查询，则认为该音视频文件是重复的，同时通过流式模糊哈希值生成文件编号，以验证文件标识的效果，其结果可用于指导文件标识的特征选择。最后，对整个系统的进行了功能测试。

本文的创新点包括以下三点：

1）针对网络流量中重复音视频早期检测难的问题，提出了一种预测性文件标识生成方法，该方法在音视频传输初始阶段识别重复音视频文件。

2）针对重复音视频早期检测效果评估优化的问题，提出了一种基于流式模糊哈希的重复音视频检测方法，该方法可以检测完整的音视频文件的重复性，检测结果可用于指导早期检测方法的特征选择优化。

3）基于上述技术实现了重复音视频实时检测系统，真实网络环境实验结果表明，该系统可在音视频文件传输初始阶段检测其重复性。

关键词：网络流，重复文件，识别方法，预测性

Abstract

With the development of the Internet, the network has penetrated into every aspect of our lives. More and more people use the network to watch and download audio and video programs, which makes audio and video traffic account for the highest proportion of network traffic. According to the 2018 internet phenomena report released by Sandvine, video traffic has accounted for 57.69% of global traffic and increased 22.43% compared with last year.

There is a large amount of repeated files in these audio and video traffic, and network middlebox like proxy servers and intrusion detection systems consume a lot of resources for processing these repeated audio and video traffic. To solve this situation, In this paper we constructs a real-time repeated audio and video files detection system, which can detect the repeated audio and video files in network traffic and guide the processing of network middlebox.

This system uses the following two technologys: 1) Predictive file identification generation method. This technology uses information entropy and mutual information as evaluation criteria, filters the features of the generated file identifiers, and generates a predictive file identification when the traffic establishes a connection. 2) A method of detecting repeated audio and video based on streaming fuzzy hashing. If the file identification is queried in the database, the audio and video file is considered to be repeated, and the file number is generated by the stream fuzzy hash value to verify the effect of the file identification, and the result can be used to guide the feature selection of the file identification.

The innovations of this paper include the following three points:

1) Aiming at the problem of the early detection of repeated audio and video in network traffic, a predictive file identification generation method is proposed, which detectes repeated audio and video files in the initial stage of audio and video transmission.

2) Aiming at the problem of evaluating the optimization of the early detection effect of repeated audio and video, a method of detecting the repeated audio and video based on streaming fuzzy hash is proposed. This method can detect the repeated audio

and video files, and the detection results can be used to guide feature selection of the predictive file identification generation.

3) Based on the above technologys, the real-time detection system of repeated audio and video is realized. The experimental results of real network environment show that the system can detect the repeatability in the initial stage of audio and video file transmission.

Keywords: Network traffic,repeated file,Identification method,Predictive

目 录

第 1 章 绪论 ····· 1
1.1 研究背景及意义 ····· 1
1.2 国内外研究现状 ····· 3
1.2.1 研究现状概述 ····· 3
1.2.2 数据链路层的网络消冗 ····· 4
1.2.3 网络层的网络消冗 ····· 5
1.2.4 应用层的网络消冗 ····· 8
1.3 小结 ····· 9
第 2 章 前人的工作基础 ····· 11
2.1 流式模糊哈希 ····· 11
2.1.1 普通哈希 ····· 11
2.1.2 模糊哈希 ····· 11
2.1.3 流式模糊哈希 ····· 12
2.1.4 采用的流式模糊哈希的原因 ····· 14
2.2 基于流式模糊哈希的相似性查找系统 ····· 15
2.3 小结 ····· 16
第 3 章 预测性文件标识生成方法 ····· 19
3.1 背景知识 ····· 19
3.1.1 决策树 ····· 19
3.1.2 贝叶斯分类方法 ····· 20
3.1.3 HTTP ····· 21
3.1.4 特征选择 ····· 22
3.1.5 信息熵 ····· 24
3.1.6 互信息 ····· 24
3.2 重复音视频实时检测的挑战 ····· 25
3.3 重复音视频文件预测实验 ····· 26
3.3.1 实验思路 ····· 26
3.3.2 实验结果 ····· 28
3.4 预测性文件标识生成 ····· 29
3.4.1 思路 ····· 29
3.4.2 生成音视频文件标识的难点 ····· 29

3.4.3 特征选择评价标准 ····· 29
3.4.4 实验数据 ····· 30
3.4.5 音视频特征信息熵和互信息 ····· 30
3.4.6 预测性文件标识生成 ····· 31
3.5 小结 ····· 31
第 4 章 基于流式模糊哈希的重复音视频检测方法 ····· 33
4.1 背景知识 ····· 33
4.1.1 单向流 ····· 33
4.1.2 流式模糊哈希相似的不足 ····· 34
4.2 基于流式模糊哈希的重复音视频检测方法 ····· 34
4.3 音视频文件编号 ····· 35
4.4 预测性文件标识评价 ····· 38
4.5 实验 ····· 38
4.5.1 实验一 ····· 38
4.5.2 实验二 ····· 38
4.6 小结 ····· 39
第 5 章 系统设计与实现 ····· 41
5.1 系统概述 ····· 41
5.2 系统的功能测试结果 ····· 42
5.3 小结 ····· 45
第 6 章 总结与展望 ····· 47
6.1 全文总结 ····· 47
6.2 研究展望 ····· 48
参考文献 ····· 49
作者简历及攻读学位期间发表的学术论文与研究成果 ····· 53
致谢 ····· 55

图形列表

1.1 系统结构图 ····· 5
1.2 基于内容分块原理 ····· 6
1.3 PACK 系统结构图 ····· 7
1.4 PACK 算法。(a) 这是发送端流程图，(b) 这是接收端流程图。 ····· 7
1.5 移动设备流量减少结果 ····· 9

2.1 多线程传输场景 ····· 13
2.2 处理乱序结构示意图 ····· 14
2.3 流式模糊哈希值 ····· 14
2.4 基于 n-gram 的标识匹配算法结构示意图 ····· 16

3.1 典型的决策树结构图 ····· 19
3.2 用户发出第一次请求 ····· 23
3.3 用户再次请求 ····· 23
3.4 特征选择的框架 ····· 24
3.5 所有音视频大小分布 ····· 27
3.6 完整度 80% 音视频大小分布 ····· 27

4.1 路由表 ····· 33
4.2 基于流式模糊哈希的重复音视频检测方法流程图 ····· 35
4.3 音视频文件编号流程图 ····· 37

5.1 面向网络流量的重复音视频实时检测系统框架图 ····· 41
5.2 完整度 80% 文件数去重 ····· 42
5.3 完整度 95% 文件数去重 ····· 43
5.4 完整度 80% 文件带宽去重 ····· 43
5.5 完整度 95% 文件带宽去重 ····· 44

表格列表

1.1 网民人数以及音视频用户人数 ····· 1
1.2 不同应用网络流量占比 ····· 2
1.3 美国下载流量排行 ····· 2
1.4 国内外研究现状总结 ····· 10

3.1 所选特征和其特征量化方式 ····· 28
3.2 数据集特征 ····· 30
3.3 特征信息熵结果 ····· 30
3.4 特征互信息结果 ····· 31

4.1 误报率结果 ····· 38
4.2 漏报率结果 ····· 39
4.3 预测性文件标识漏报率实验结果 ····· 39

5.1 内容分析模块有害音视频文件召回数 ····· 42

第 1 章　绪论

1.1　研究背景及意义

随着互联网的发展，网络已经渗入到我们生活的方方面面，越来越多的人使用网络观看和下载音视频节目，这也使得音视频流量已经成为网络流量中占比最高的部分。

根据中国互联网信息中心 (CNNIC) 发布的第 42 次《中国互联网络发展状况统计报告》CNNIC (2018) 显示。截至 2018 年 6 月，如表 1.1所示，我国的网民规模达 8.02 亿人，其中网络视频用户约为 6.09 亿人，较半年前增长了 5.7%，而网络音乐用户约为 5.55 亿人，较半年前增长了 1.2%。

表 1.1 网民人数以及音视频用户人数

Table 1.1 Number of netizens and number of audio and video netizens

	2017.12 用户规模 (万)	2018.6 用户规模 (万)	半年增长率
网民总数	80166	77198	3.8%
网络视频用户	57892	60906	5.2%
网络音乐用户	54809	55482	1.2%

其中网络直播和短视频用户飞速增长，2017 年起，尤其在 2018 年春节期间，短视频应用迅速下沉至三、四线城市，用户规模持续增长。截至 2018 年 6 月，综合各个热门短视频应用的用户规模达 5.94 亿人，而网络直播的用户规模也达到 4.25 亿人，较去年年末微增 294 万人。

随着通过网络观看音视频节目的人数不断增加，音视频流量也早已成为网络流量中占比最高的流量，根据 sandvine 发布的 2018 年全球互联网观察sandvine (2018) 显示，如表 1.2所示，视频流量已经占据全球流量的 57.69%，较去年增长了 22.43%。

而美国下载流量前十位的应用中，有四种应用是提供音视频服务的应用，如表 1.3所示，分别为 netflix，youtube，http media stream，amazon prime。

而根据cisco (2018)，到 2022 年全球音视频流量将占到全球网络流量的 82%，高于 2017 年的 75%。从 2017 年到 2022 年，互联网视频流量将增长四倍，复合年增长率约为 33%。

表 1.2 不同应用网络流量占比

Table 1.2 Different application network traffic ratio

应用名	流量占比	全年增长率
视频流	57.64%	22.43%
网页	17.01%	20.98%
游戏	7.78%	2.68%
社交媒体	5.10%	3.73%
电子商务	4.61%	1.90%
文件分享	2.84%	22.05%
即时通讯	1.72%	8.12%
安全	1.41%	7.48%

表 1.3 美国下载流量排行

Table 1.3 US download traffic rank

应用名	流量占比	全年增长率
NETFLIX	14.97%	2.92%
HTTP MEDIA STREAM	13.07%	4.84%
YOUTUBE	11.35%	3.03%
RAW MPEG-TS	4.39%	4.11%
HTTP (TLS)	4.06%	2.06%
QUIC	3.87%	1.43%
AMAZON PRIME	3.69%	0.87%
HTTP DOWNLOAD	3.69%	1.45%
HTTP	3.22%	4.80%
PLAYSTATION DOWNLOAD	2.67%	0.45%

可见大量的音视频流量通过网络进行传播，而这些音视频流量中又存在大量重复的音视频文件，代理服务器，入侵检测系统等网络中间件需要通过处理分析流量，以达到版权保护、色情检测等目的。然而对这些重复的流量消耗了这些网络中间件大量带宽，存储和处理资源，同时也降低了整个网络内部的性能。如果这些网络中间件能在音视频流量建立连接时，对这些重复的音视频文件进行检测，就可以提高网络性能并节约服务器资源。

面向网络流量的重复音视频文件实时检测系统，其有两个要求：

1. 检测实时性：为了在网络流量中检测重复的音视频文件，从而减少代理服务器等网络中间件的消耗，首先要尽可能在传输结束前完成检测。所以选取的特征应主要为音视频流量头部的信息，以保证检测的实时性。

2. 算法的准确性：由于代理服务器入侵检测系统等网络中间件需要对网络流量进行分析从而达到版权保护和色情检测的目的。因此对于音视频文件的重复性检测，其对准确度的要求较高。

综上所述，在网络流中识别重复的音视频文件具有重要意义。针对网络流量中音视频文件的重复传输问题，本文将提出一个准确性高的、实时的重复音视频文件实时检测系统用以指导代理服务器、入侵检测系统等网络中间件对网络流量中的音视频文件进行重复性检测。

1.2 国内外研究现状

1.2.1 研究现状概述

在前人的研究中，在网络流量中对重复的音视频文件实时检测主要可以分为两种方法: 第一种基于流量数据本身，不进行音视频文件的编解码，即网络冗余发现系统。网络冗余发现系统现大量应用于云计算，企业内部网络等。网络冗余发现系统的大量应用大大减少了企业的网络建设成本。第二种是基于对网络传输的音视频流量进行编解码，即大规模相似音视频检索（NDVR ）系统。该系统大量用于版权保护领域，其准确度较高，但却需要消耗大量的资源。

Spring 和 Wetherall (2000) 提出一种无需对网络协议进行解析的网络冗余发现技术，该论文首次提出一种基于端到端模型的网络冗余发现系统，而后人提出的大部分的网络冗余发现系统也是基于端到端的模型进行实现。

Anand 等 (2009) 等人提出了一种新的网络冗余发现系统及其算法，主要的思路是通过对比新请求和旧请求的数据来检测和删除重复的块，通过消除数据的重复传输，以减少冗余数据对资源的消耗从而提高整个网络的性能。

还有一些网络冗余发现系统带有一定的预测功能。Zohar 等 (2014) 等人提出一种具有预测性的网络冗余发现算法, 该方法与前人提出的基于端到端网络冗余发现系统的不同点在于，该方法不要求服务器持续维护客户端状态（紧密的缓存同步问题），从而大大地减少了服务器的开销。

除了基于端到端的网络冗余发现系统以外，还有一种通过网络缓存的方式来减少内部网络的带宽开销，如，Anand 等 (2010) 提出了一种用于企业内部网络的网络缓存策略，使得内网的流量减少了约为 65%。

同时网络冗余发现系统也被用在了不同的网络细分领域，与使用的场景密切结合，用于减少该场景下资源的消耗。Lei 等 (2013) 提出了一种基于端到端的网络冗余发现方案，以用于云计算中的网络冗余发现，该系统即能够发现短冗余又能发现长冗余。Aggarwal 等 (2010) 提出的网络冗余发现系统被用于广域网的优化。Sanadhya 等 (2012) 将现有的网络冗余发现技术用于手机中，实验结果表明可以减少约 30% 的手机流量。Halepovic 等 (2012) 在数据链路层来解决无线局域网中的网络冗余问题，同时在该论文中也首次提出了在无线网络中发现网络冗余的四个挑战。

第二种方法是对网络中传输的音视频文件进行编解码，之后通过基于音视频内容的检测方式，其优点是检测的准确率较高，大量应用于版权保护领域。Hao 等 (2016) 为了提高检索相似音视频的准确性和速度，提出了一种新的随机多视图哈希算法，以促进大规模相似音视频检索（NDVR ）系统的构建。最后使用两个公开的相似音视频数据集对该系统进行检验，与各种最先进的 NDVR 系统进行比较有着较明显的优势。NDVR 系统虽有较高的准确度但无法在内存集约的情况下工作，且无法对网络流量中的音视频文件进行相似性检测。下面我将详细介绍一下前人对于网络冗余发现系统的解决方案。

1.2.2 数据链路层的网络消冗

首先介绍一下数据链路层的网络冗余发现和删除。

2010 年 SIGCOMM 上，Lumezanu 等 (2010b) 等人发表的一篇论文提出了一种针对蜂窝数据网络的冗余发现和消除方法。在该篇论文中，作者在蜂窝络中部署网络冗余发现系统，可以大大减少运营商的网络带宽成本。

由于蜂窝链路具有更高的丢包率，给整个网络冗余发现系统带了巨大的挑战。该论文作者提出了一种轻量级机制，来应对此问题。作者将该系统部署在两个北美和一个欧洲运营商处，最终实验表明该网络冗余发现系统可以将大多数

移动用户的带宽消耗降低至少约 10%，其中部分带宽消耗减少高达 50%，取得了良好的效果。

Halepovic 等 (2012) 等人在 2012 年 ICC 上发表的一篇论文提出了一种针对无线局域网链路层的网络冗余发现系统。

在论文中，作者证明了网络冗余发现系统是可以使用在无线局域网中，同时将其和使用在以太网中的网络冗余发现系统进行了比较，并提出了无线局域网网络冗余发现系统所面临的两个挑战，分别是数据帧的丢失和 IP 数据的比例（由于无线局域网的数据包中包含大量管理和控制帧，导致 IP 数据的比例下降）。

最终作者通过实验证明，虽然网络消冗系统在无限局域网中的效果并没有在以太网中那么明显，但依旧可以节约 23% 的带宽消耗。主要的原因是数据链路层需要对丢失的帧进行再重传，产生了大量的额外流量。

可见，部署在数据链路层主要的挑战在于，数据链路层会出现大量的帧丢失的现象，从而大大减弱了网络冗余发现系统的效果。

1.2.3 网络层的网络消冗

由于数据链路帧丢失现象比较严重，大量的网路冗余发现系统都工作在网络层和应用层，从而避免对大量的帧丢失进行处理。下面是对网络层的网络冗余发现系统的介绍。

Spring 和 Wetherall (2000) 等人提出了一种识别重复数据传输的技术，并用它来分析网络流量的冗余。该网络冗余发现系统的结构图如图1.1所示。整个系

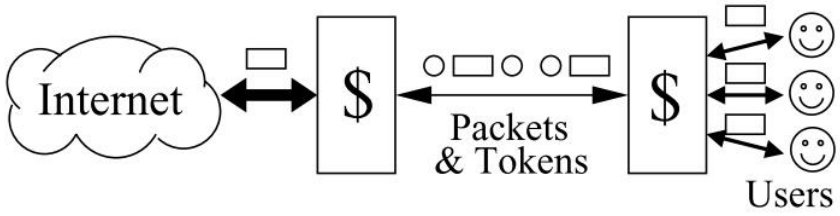


图 1.1 系统结构图

Figure 1.1 System structure diagram

统分成发送端、接收端和存储数据块及其指纹的数据集，该数据集在发送端和接收端进行紧密的缓存同步。该系统是一个典型的基于端到端模型的网络冗余发现系统, 系统所使用的模型和算法思想也影响了许多后人的工作。

首先介绍一下发送端的流程：

第一步：首先发送端对网络流量基于内容进行分块，使用了滑动窗口技术，用拉宾指纹算法来确定网络流量分块的边界，使用拉宾指纹进行网络流量分块的目的是为了避免不变的分块对数据的更改十分敏感。其原理如下图1.2所示。

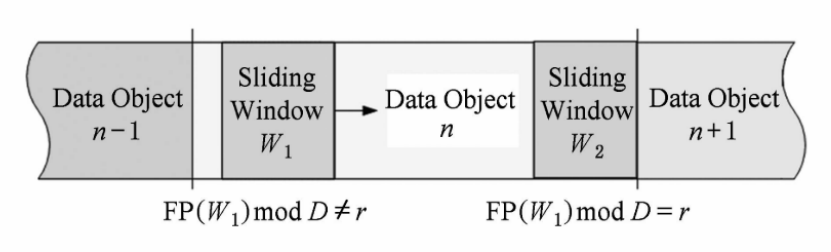


图 1.2 基于内容分块原理

Figure 1.2 Content-based block principle

第二步：每次计算给定滑动窗口 W 内的数据内容的指纹 FP（如 W），并基于最大给定的大整数 D 取模后，与给定的余数进行了对比；若相等（如 W2）则窗口的右端为数据划分边界，否则（如 W1）将窗口继续往右滑动一个字节，依此循环地进行计算和对比，直到达到文件末尾。基于内容分块可以将更改对数据划分的影响控制在更新位置附近的少数几个分块内，并保持其他分块不变。

第三步：发送端将分块后的数据在数据集中进行搜索，若发现该数据块已经在之前出现过，则将该分块替换成其在数据集中对应的指纹。若发现该数据未在之前出现过，则使用新的指纹对需要传输的数据块进行标记，并存储在数据集中，并将新指纹和传输的数据块一起发给接收端，以保证接收端的数据集的更新。

接着介绍一下接收端的流程：

接收端收到发送端的网络流量后，需要对网络流量进行还原，若是新指纹，则记录在数据集中。若是旧指纹，则对指纹进行还原，填充相应的数据块。

Yu 等人提出了 PACK 作为压缩算法，实现了一个专门为云计算设计的网络冗余发现系统。该系统的结构图如图1.3所示。

整个系统也采用了典型的基于端到端的模型，但本文提出了一种新的网络冗余发现算法 PACK，不同于以往的算法，PACK 有一定的预测性质，从而减少了网络的传输带宽，同时 PACK 也减少了发送端的开销，无需发送端和接收端紧密缓存两个数据集。如图1.4所示，分别是发送端和接收端的算法结构图。

同时该系统无需安装新的协议，可适用于所有基于 TCP 的应用程序和网络设备，这也是使用 PACK 网络冗余发现算法的优点之一。

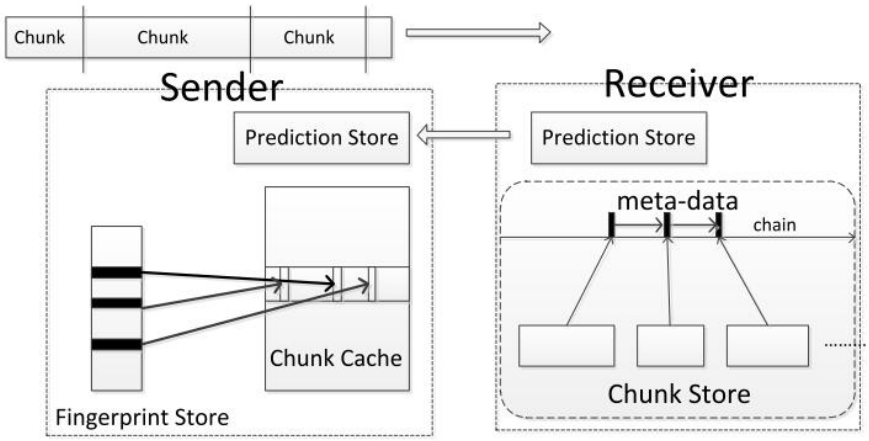


图 1.3 PACK 系统结构图

Figure 1.3 PACK system structure

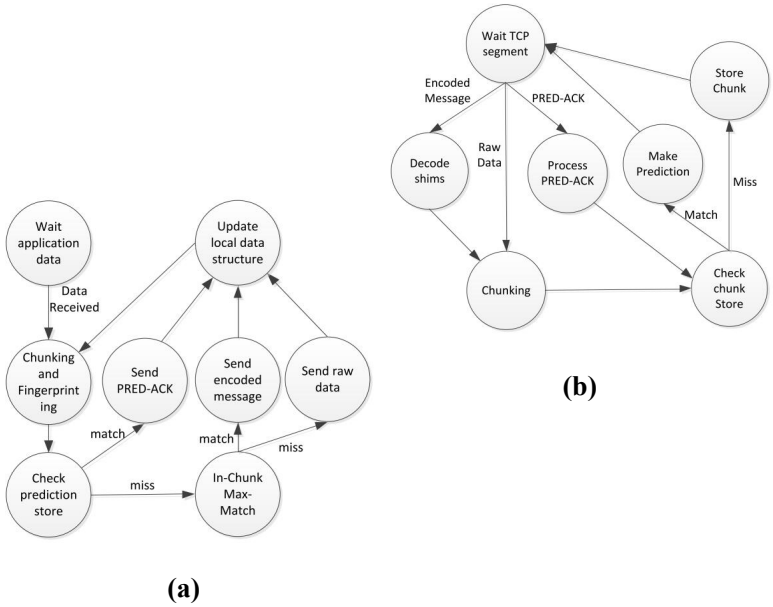


图 1.4 PACK 算法。(a) 这是发送端流程图，(b) 这是接收端流程图。

Figure 1.4 PACK algorithm.(a)PACK sender algorithm,(b) PACK receiver algorithm.

1.2.4 应用层的网络消冗

最后介绍应用层的网络冗余发现系统。

在 2012 年的 NSDI 上，Aggarwal 等发表一篇文章，提出一种不同于中间件的网络冗余发现系统，其可对加密流量进行网络冗余发现，且适用于最后一跳是移动设备的应用场景，同时使用了一种新的优于拉宾指纹的算法。

该篇论文中提到了一些基于中间件的网络冗余发现系统的缺点，其缺点主要有以下两点：

1) 基于中间件的网络冗余发现系统，不能很好地应对加密流量，而目前大量的网络流量采用了加密协议，这也使得许多网络冗余发现系统的效果大大降低，只能对非加密流量进行分析。

2) 随着移动互联网的兴起，越来越多的人使用手机，而基于中间件的网络冗余发现系统无法提高移动设备中最后一跳链路的性能。

同时作者也提出了一个新的网络冗余发现算法，该算法无论在缓存开销和 CPU 占用都优于以往的算法。但缺点在于无法发现较短的冗余。

针对网络加密协议的兴起和移动设备的不断发展，作者提出了这一的网络冗余发现系统。但该系统需要在用户的电子设备额外安装一个新的客户端，而编解码的工作是由原本的 TLS 协议完成，因此该系统只是适用于企业内部网络，以减少企业在网络建设上的消耗。

同时，从 2012 年起，对移动设备的网络冗余发现也越来越得到了人们的关注。

Feng 等 (2013) 发表一篇文章提出了一种组合不同的网络冗余发现和消除技术的方法，如：增量编码，网络缓存等。在移动网络中减少了约 30% 的流量。

本文的作者调查了移动设备上的 HTTP 缓存使用情况，发现移动设备对于 Web 缓存，协议规范与电脑设备之间存在巨大差距。完全支持 HTTP 缓存协议并且严格遵循该协议的智能手机应用程序和移动浏览器，可以减少约 17% 左右的移动流量。

最后作者采用了现有的四种冗余发现方法，分别采用了 HTTP 缓存，文件压缩，增量编码和数据包流压缩 (MODP), 其结果如图1.5所示。

	caching +gzip	caching +bzip2	caching +7-zip	caching +gzip +delta	caching +bzip2 +delta	caching +7-zip +delta	All * n=512k p=1/4	All * n=256k p=1/8	All * n=128k p=1/16	All * n=64k p=1/32
HTTP	71.4%	71.6%	70.4%	71.1%	71.3%	70.1%	-	-	-	-
All	75.5%	75.8%	74.7%	75.3%	75.5%	74.5%	68.1%	68.6%	69.2%	69.9%

* All = caching + gzip (lv 5) + delta + MODP (for all traffic). n and p are MODP parameters.

(a)

	1. Caching	2-4. File Compression (lv 1–9)			5-7. Lower Bound (lv5)			8-9. Δ Encoding	
		gzip	bzip2	7-zip	gzip	bzip2	7-zip	T & NT*	NT only
HTTP	79.8%	83.9–84.5%	84.4–84.9%	82.5–82.5%	80.4%	78.9%	71.7%	77.8%	98.0%
All	82.7%	86.3–86.8%	86.7–87.1%	85.1–85.1%	83.3%	82.0%	75.8%	81.0%	98.3%

* "T": trivial cases (two versions are identical); "NT": non-trivial cases (two versions are different).

(b)

图 1.5 移动设备流量减少结果

Figure 1.5 Mobilephone traffic reduce results

1.3 小结

最后是对国内外研究现状的总结。这些研究现状要么无法对网络流量重复进行实时检测，要不是都是基于端到端系统，未使用中间件的方式。而基于音视频内容的 NDVR 系统消耗大量的资源，且实时性较差，并不适合在网络传输环境中使用。但这些国内外研究现状却有许多可借鉴之处：一是应充分考虑网络传输中丢包，乱序等特性对检测结果的影响。二是应充分考虑不同网络设备的适用。三是应充分考虑内存消耗的问题，提出的方法应可以工作在内存集约的情况下，整个国内外研究现状的总结，见表1.4所示：

表 1.4 国内外研究现状总结

Table 1.4 Summary of research status

研究方法	代表工作	会议	创新点
链路层	RTE in WLAN	ICC’12	解决了数据帧的丢失和 IP 数据的比例下降的问题。
	Effect of Packet loss	SIGCOMM’10	首次将网络冗余发现系统应用于蜂窝数据网络。
网络层	Protocol-independent RE Algorithms	ICC’12	首次提出基于端到端的网络冗余发现系统，且可应用于任何非加密流量。
	end to end TRE	ICNP’12	可不同网络设备的适用，专门为云计算设计的网络冗余检测和消除算法。
应用层	EndRE	NSDI’12	适用于加密流量和最后一跳是移动设备的应用场景，同时使用了一种新的优于拉宾指纹的算法。
	Combination of different techniques	PAM’13	组合不同的网络冗余发现和消除技术的方法，如：增量编码，网络缓存等。在移动网络中减少了约 30% 的流量。
	PACK	TON’14	提出了一种具有预测性的网络冗余监测系统，大大减少了服务器端的压力。
基于内容	NDVR	TMM’17	提出了一种新的随机多视图哈希算法，以促进大规模相似音视频检索（NDVR）系统的构建。最后使用两个公开的相似音视频数据集对该系统进行检验，与各种最先进的 NDVR 系统进行比较有着较明显的优势

第 2 章　前人的工作基础

本章将详细介绍整个系统所使用的两个前人的研究成果，分别是流式模糊哈希和基于流式模糊哈希的相似性查找系统。接着介绍使用这些研究成果的原因和各自的优缺点。

2.1　流式模糊哈希

2.1.1　普通哈希

首先介绍一下什么是哈希算法，哈希算法从数学上看是一种函数映射，而目前如：MD5，SHA1，CRC32 等常见的哈希算法，其可以将任意大小的文件或者任意长度的字符串映射成一个固定长度的字符串，由于最后生成的哈希值较原来的文件要小很多，许多哈希算法也常用于文件的重复性检测，成为大文件的唯一标识。

但像上文提到的 MD5 和 SHA1 等哈希算法，其具有雪崩效应。当文件中的任意一个比特位发生改变时，会导致生成的哈希值完全不同。虽然这一特性对于检测文件是否缺损，或者检测文件是否改变有着重要作用，但却无法对于两个文件进行相似性检测。为了解决这一问题，诞生了模糊哈希，和上文提到的普通哈希相比较，模糊哈希可以比较两个不同版本文件的相似度，其主要使用在计算机数字取证领域和恶意代码分析。

2.1.2　模糊哈希

模糊哈希的概念源于 Andrew Tridgells 等人的工作称为 spamsum，而 Kornblum 等人开发了 ssdeep 则主要用于数字取证领域。与普通哈希算法 MD5 和 SHA1 相比，模糊哈希可以识别文件的细微更改，例如，将字符插入文档。这一特性也使得模糊哈希大量应用于入侵检测系统，Tridgell 等人在开发一种识别垃圾电子邮件系统时，开发了一种具有许多独特属性的签名算法。以上的工作都是模糊哈希在工业界和学术界的应用，模糊哈希的特点如下：

非传播（Non-propagation）：在 spamsum 算法中，只有与二进制的变化部分线性对应的 spamsum 哈希值部分才会被更改。这意味着文件中任何部分的微小变化都不会引起加密后的哈希值急剧变化。

对齐鲁棒性（Alignment robustness）：大多数哈希算法都对比较两个文件是

否对齐十分敏感。仅仅删除或向文件中插入单个字节将导致最后生成两个完全不同的哈希值。而 spamsum 算法的核心是用于在二进制中生成一系列重置点的弱哈希（rolling hash）。且该重置点仅取决于直接上下文。下面将对该模糊哈希算法进行详细介绍。

如公式2.1，模糊哈希使用名为块大小 b 的变量来触发重置点，块大小可以用 1 计算，这可以确保某个文件的模糊哈希结果长度既不会太长不能比较，也不会太短从而避免冲突。bmin 是常量最小块大小，S 是常量预期模糊散列长度，n 是输入文件大小。值得注意的是，文件大小并不总是在网络流量中可用。

$$b_{init} = b_{min}2^{\lfloor \log_2(\frac{n}{Sb_{min}}) \rfloor} \tag{2.1}$$

k 窗口的弱哈希函数在 k 字节的输入序列：c1、c2、……ck，当满足公式2.2时，重置点将位于 ck。根据统计上，当 b 值越小时，越多重置点将触发。然后使用基于 FNV 算法的强哈希来产生两个重置点之间区域的哈希值。最后将来自每个重置点 FNV 哈希中的字符进行串联，得到最终的模糊哈希值。字符串编辑距离算法将用于检测不同文件的模糊哈希值的相似性。

$$rolllinghash(c_1, c_2, ..., c_k) mod b = b - 1 \tag{2.2}$$

2.1.3 流式模糊哈希

正如上文所提到的那样，模糊哈希算法已被应用于许多领域，因为它能够比较两个不同的文件并确定其相似性。然而，在网络流量中使用模糊哈希来识别正在传输中的相似文件时，却遇到了许多问题和挑战：

1）无法确定文件长度：文件长度可能在文件传输结束之前无法确定。例如，在 Http 1.0 及之前版本中，content-length 字段是可有可无的。而在 http1.1 及之后版本。如果是 keep alive 模式，则 content-length 和 chunk 字段二选一。若是非 keep alive 模式，则和 http1.0 一样，content-length 可有可无。文件长度虽然对于像 MD5 和 SHA-1 这样的哈希算法可有可无。但是，文件长度是模糊哈希生成的关键参数之一，因为它用于生成之前提到的触发值以生成哈希片段，就是上文所提到的块大小。

2）单向处理：为了生成适当长度的签名，模糊哈希需要调整弱哈希触发值并迭代计算。但由于网络流量具有高吞吐量的特性，例如 10 千兆以太网，将网

络中传输的音视频文件完全存储在硬盘上是不切实际的，因此没有第二次重新计算的机会。

3）无序输入：最先进的传输技术将文件分成片段以实现传输的高效性和灵活性，例如多线程下载，P2P 文件共享和网络中继服务（例如 Mega 上传和百度云）。如图2.1是典型的多线程传输场景，其中灰色块表示文件片段。在时间 t3，可能出现 0-3M 范围内的任何文件片段。模糊哈希算法只能从文件头或复位点进行计算，因此必须缓冲无序片段，直到收到所有前面的数据。在最坏的情况下，几乎整个文件都被缓冲，这使得内存消耗是十分巨大的。

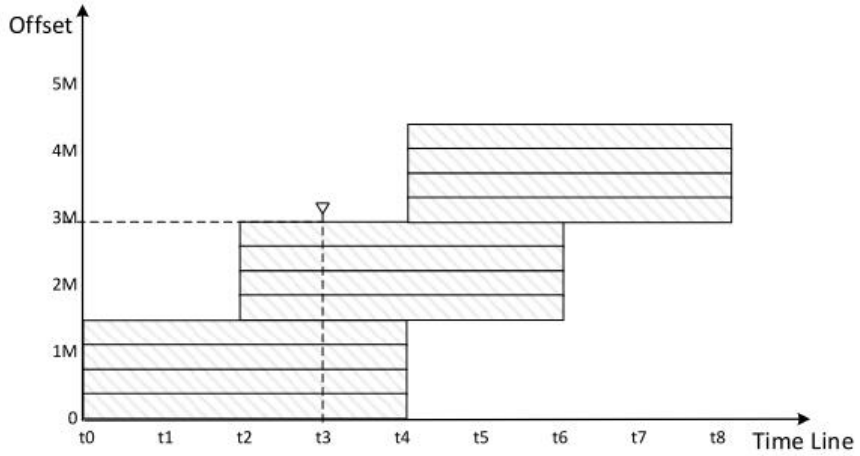


图 2.1 多线程传输场景

Figure 2.1 Multi-threaded transmission scenario

4）不完全捕获：由于数据包丢失或处理错误，从网络流量捕获的文件不完整是一种常见的观察结果。数据包丢失是入侵检测系统（IDS）或数据泄漏保护（DLP）等中间件中的常见问题。同时，还有一些人为因素会影响捕获文件的完整性。例如，拖动在线视频的进度条，或手动关闭传输会话。

而流式模糊哈希使用上下文记录每个离散数据段的计算结果，考虑到在网路传输过程中无序数据段是常见的，且每个数据段都会生成一个段上下文。流式模糊哈希使用 Tillich-Z’emor 哈希而不是 FNV 作为强哈希函数，这使流式模糊哈希缓冲每个离散段不超过 6 个字节。此外，通过细粒度的自适应机制，流式模糊哈希可以仅一次处理流量就可以生成哈希签名。如果在传输后确认文件不完整，则文件的缺失部分不会影响其他间隔，因为每个签名都是单独生成的。其算法的优点如下：

1）可以生成流式数据的摘要，用于网络流量的相似性检测。引入多个区间

数据索引以及中间状态，以满足复杂的网络环境中数据块的无序输入，使得传统的模糊哈希算法可以生成网络流量的摘要。流式模糊哈希处理乱序的流量输入结构图如图2.2:

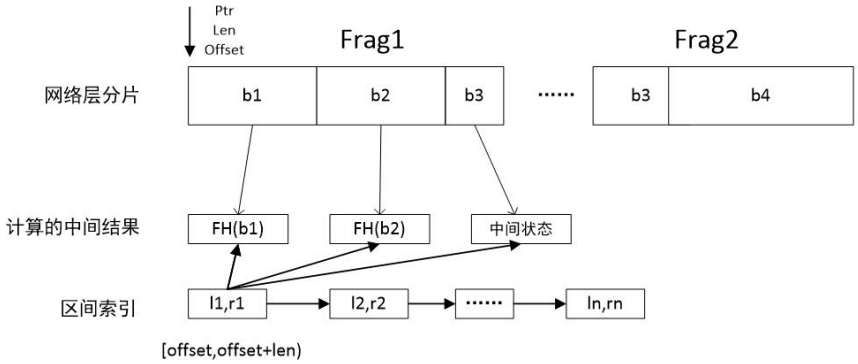


图 2.2 处理乱序结构示意图

Figure 2.2 Handling out-of-order structure

2）可以在内存集约的环境下工作，从而降低代理服务器、入侵检测系统等网络中间件的开销。

3）只要对流量处理一次就可以生成模糊哈希值，无需对海量的流量进行存储。

典型的流式模糊哈希值如图2.3所示：

5Howh395h39h/ZF9e3Tg6S9d8CY9QXA4A5A4z48ZQdVZcuXVBA
IkV2R3prfywFlL8xwY2[0:36746924]

CKStpol/OlnrBBIphB05v1E5qe[0:490021]Y8mWpVC23no6pzuhk
NJFI3GwfEielWUyoEP6QCCMfZlowXRKI1JoLb[523900:950187]

图 2.3 流式模糊哈希值

Figure 2.3 Streaming Fuzzy Hash

2.1.4 采用的流式模糊哈希的原因

在网络流量中识别重复的音视频文件需要一个基准的文件编号来识别文件是否重复，流式模糊哈希的使用其目的就是为了判断在网络流量中的音视频文件是否重复，从而计算后文提到的音视频文件编号并验证音视频文件标识的准确性。

上文提到了，流式模糊哈希三个优点：

1）可以生成流式数据的摘要，用于网络流量的相似性检测。

2）可以在内存集约的环境下工作。

3）只要对流量处理一次就可以生成模糊哈希值。

以上的三个优点使得流式模糊哈希可以在代理服务器中使用，以获取真实环境中的音视频流量摘要。但由于用户的观看习惯和大量的音视频网站采用流媒体技术，所以导致了缺损的不完整的音视频文件。对于完整度较低文件的相似性比较，流式模糊哈希有着一定的局限性。

下文将在真实环境中的代理服务器中部署流式模糊哈希算法，并计算音视频流量的摘要，以获取真实环境的数据，来帮助判断网络流中传输的音视频文件是否重复。

2.2 基于流式模糊哈希的相似性查找系统

如果采用流式模糊哈希对网络中传输的音视频流量进行标记，会产生大量的流式模糊哈希值。当需要对这些音视频文件是否重复进行判断时，需要进行大规模的字符串相似性比较。

传统的字符串相似性比较是通过计算两个值之间的编辑距离，若两个字符串的编辑距离越小，则认为这两个字符串越相似。编剧距离的定义是，将一个字符串转换成另一个字符串所需要的最少单字符编辑操作次数。而允许的单字符编辑操作有：插入、删除和替换。计算两个字符串之间的编辑距离是一项极其耗费时间的工作，计算一次编辑距离的时间复杂度为 O(n2)，为了减少大规模流式模糊哈希值相似查找的时间，该系统使用了一种基于 n-gram 索引的模糊哈希匹配算法。

现假设需要在 m 个流式模糊哈希值中，找到和要查询的哈希值最相似的流式模糊哈希值，为了进行哈希值匹配，必须构建索引以减少要比较的字符串的数量。N-gram 是构建索引的常用方法。因此，在构建示例数据集时，哈希值会通过 N-gram 分解以建立索引。N-gram 是来自给定字符串的 n 个字符的连续序列。为了生成 n-gram，它每次从第一个字符向前移动一步字符。例如，如果 n 为 3，则字符串“abcde”将溢出为“abc”，“bcd”和“cde”。每个 gram 的长度可以是任何常数。在真实环境中，一般采用 7 作为 gram 的长度。整个系统的结构图如图2.4所示。

然后将这些流式模糊哈希生成的 gram 插入哈希表中。通过 n-gram 建立索引的一个问题是随着字符串数量的增长，一个 gram 的链接列表可能太长。该查找

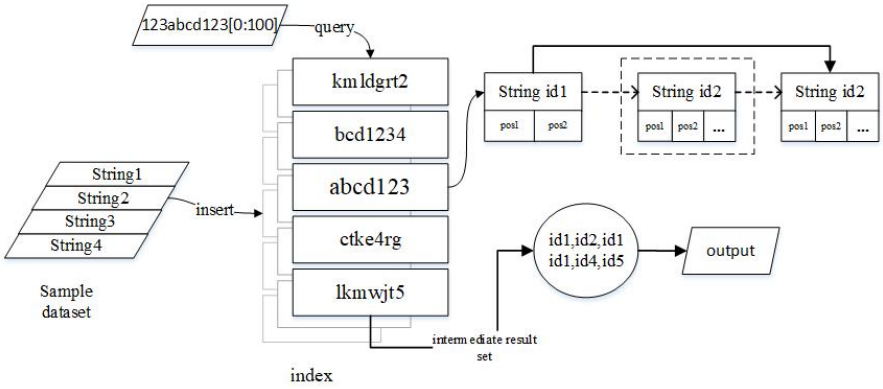


图 2.4 基于 n-gram 的标识匹配算法结构示意图

Figure 2.4 Schematic diagram of n-gram-based identification matching algorithm

系统通过剪枝被用来解决这个问题。

在进行相似查询时，系统将查询的模糊哈希的字符串分为几个块。为了在查询时进行加速，使用 n-chunk 代替 n-gram。因为字符串的块数小于 gram 数。n-chunk 也是来自给定字符串的 n 个字符的连续序列。但是 n-chunk 每次从第一个角色向前移动 n 步。以字符串为例，如果 n 为 3，则字符串“abcdef”将溢出为“abc”和“def”。

在此之后，将块放入哈希表中以搜索是否存在相同的块。最后评价相似度的时候使用如下公式2.3：

$$cfds = 10 * \left(\frac{C}{chunk_cnt}\right)\left(\frac{gram_cnt}{left_gram_cnt}\right) \tag{2.3}$$

其中 C 表示出现次数，chunk_cnt 表示查询的 string 中包含 chunk 的个数，Gram_cnt 表示查询串的 gram 的个数，left_gram_cnt 表示被比较的字符串 gram 个数。

2.3 小结

本章主要介绍了两个前人的工作以及其实现原理，分别是流式模糊哈希算法和基于流式模糊哈希算法的相似性查找系统。以上两个前人的工作在之后的文章中大量使用。

流式模糊哈希主要是在真实环境中生成音视频流量的摘要，这样就无需对整个网络流量中传出的音视频文件进行存储，极大的节约了存储的消耗。

基于流式模糊的相似性查找系统主要用于流式模糊哈希的相似性查找，以

判断网络中传输的音视频文件是否重复，其优化了字符串匹配的查找算法，其对800 万条的查询速度可以达到 2 万次/秒。

第 3 章　预测性文件标识生成方法

本章将简要介绍相应的背景知识，重复音视频实时检测的挑战，接着使用传统的机器学习方法预测文件的重复性，然后详细说明最终采用的生成预测性文件标识的方案以及该方案的步骤和难点。

3.1　背景知识

介绍决策树和朴素贝叶斯之前，首先介绍一下什么是分类。分类是一种重要的数据分析形式，其通过一些算法提取并刻画重要数据类的模型，即分类器。通过该分类器可以对现有的数据进行分类，已达到预测的效果，而决策树和朴素贝叶斯都是非常经典和常用的分类器。

3.1.1　决策树

决策树是一种类似于流程图的树结构，其中每一个非树叶节点可以认为其是数据集中的一个属性上的测试，而决策树的每一个分支代表一个测试的结果。而每个树的树叶节点存放着一个类的标号，树的最高的顶层节点是根节点，一个典型的决策树的模型如图3.1所示。

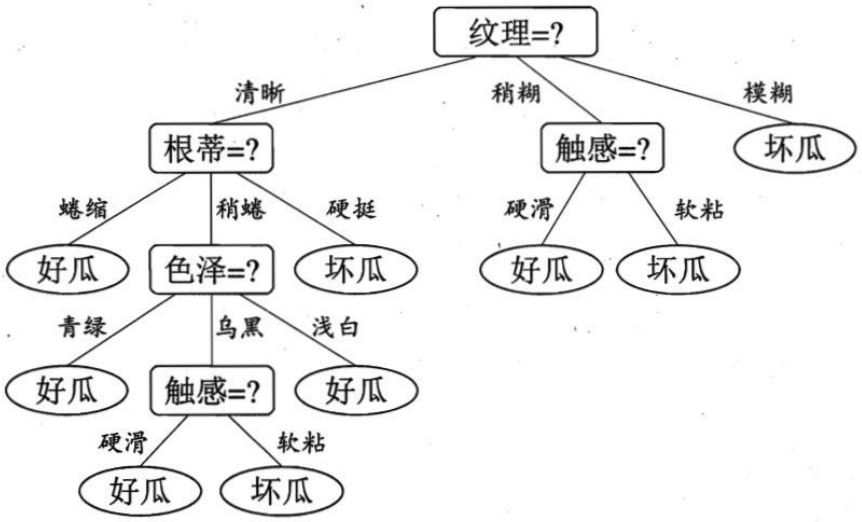


图 3.1 典型的决策树结构图

Figure 3.1 Typical decision tree

决策树的构建不需要任何领域的知识和参数设定，所以非常适合用于探索

式的知识发现。J.Ross Quinlan 等人开发了 ID3 决策树算法，此项工作扩展了 E.B Hunt 等人的工作。而 Quinlan 等人后来提出了 C4.5 决策树。

所有的决策树都采用了类似于贪心算法的思想，绝大多数的决策树分类算法都采用了自上而下的递归算法去构建整个树的结构。随着决策树不断地构建，用于训练决策树的训练集会不断地减少，下面介绍介绍一下决策树地归纳算法。

用三个参数对决策树进行训练，分别是 D，attribute_list 和 attribute_selection_method。参数 D 是数据分区。一开始，其是已经标注过地数据集的全集，参数 attribute_lis 用于标识整个标注数据集的属性列表，attribute_selection_method 参数用于标识整个标注数据集属性的启发过程，该过程的思想就是贪心算法，用属性选择度量最好的属性进行分类。属性选择的度量方法有很多种，如信息增益和基尼系数等。属性选择的度量方法会导致决策树的树形结构有所不同，比如使用基尼系数其生成的树形结构一定是二叉树。

树的生成从节点 N 开始，N 也是标注数据集 D 中的一个训练数据集，如果训练集 D 中的数据其所有的属性是同一类，则节点 N 变成该决策树的叶子节点，并用其所标注的属性来标记它。如果训练集 D 中的数据其所有的属性不是同一类，则调用 attribute_selection_method 方法，对训练集 D 进行分裂属性，选择度量会告诉我们如何对训练集进行划分。

常见的分裂准则有信息增益、基尼系数等，例如经典的 ID3 决策树就使用了信息增益作为属性选择度量。

3.1.2 贝叶斯分类方法

贝叶斯分类方法是一种统计学分类方法。它可以预测类隶属关系的概率，如给定的元组属于一个特定类的概率。

贝叶斯定理是由 Thomas Bayes 这名英国牧师所发明的，其也是概率论和数理统计的早期研究者之一。

需要了解贝叶斯定理，需要知道一些概率论和数理统计的相关知识，通常，X 用于 n 个属性集的测量描述。令 H 为某种假设，如果数据元组 X 属于某个特定类 C。对于分类问题，希望确定给定“证据”或观测数据元组 X，假设成立的概率为 P(X|H)。用通俗易懂的说法说，对于给定的 X 的属性描述，找出元组 X 属于类 C 的概率。而 P(X|H) 是后验概率，相反的，P（H）为先验概率，或者称之为 H 的先验概率。类似的，P(X|H) 是条件 H 下，X 的后验概率。

贝叶斯定理提供了一种由 P(X)、P(H) 和 P(X|H) 计算后验概率 P(H|X) 的方

法贝叶斯定理见公式3.1：

$$P(H|X) = \left(\frac{P(X|H)P(H)}{P(X)}\right) \tag{3.1}$$

用向量 $X = x_n$ 标识每个元组的 n 维属性朴素贝叶斯分类的流程如下：

假设由一个 m 个类的分类方式，其中的类别分别用 $C_1, C_2, \cdots, C_m$ 表示，给定元组 X，朴素贝叶斯分类方法将预测 X 属于具有最高后验概率的类（在条件 X 下）。换句话说，朴素贝叶斯分类方法预测 X 属于类 C_i，当且仅当 $P(C_i|X) > P(C_j|X)$，然后根据上面提到的贝叶斯定理最大化 $P(C_i|X)$。

由于 $P(X)$ 对于所有的类来说是一个常数，所以仅仅需要 $P(X|C_i)P(C_i)$ 最大即可。若类的先验概率未知，则通常假设这些类都是等概率的。也就是说 $P(C_1) = P(C_2) = \ldots = P(C_m)$, 并以此为依据对 $P(X|C_i)$ 做最大化估计而给给定了许多属性的数据集，想要计算 $P(X|C_i)$ 的值，需要消耗大量的时间，为了能够降低 $P(X|C_i)$ 计算时所消耗的资源，遂对计算进行简化。可以用类条件独立的朴素假定，将 $P(X|C_i)$ 的计算简化成公式3.2:

$$P(X|C_i) = \prod_{k=1}^{n} P\left(P(X_k|C_i)\right) \tag{3.2}$$

3.1.3 HTTP

HTTP 是互联网上用于通讯的协议方案，主要用于可靠数据的传输，也是基础的网络协议之一。下面将简单介绍一下 HTTP 报文和缓存、资源标识符相关的一些标签。

首先介绍的是 URL，URL 是统一资源定位符，通俗的理解就是互联网上的邮编地址，可以在全世界范围内对你所访问的资源进行唯一的标记。URL 可以从一个特定的服务器来获取资源。

大多数 URL 会遵循一种标准，这种标准包含以下三个方面：URL 的第一个部分是指所访问的资源类型所使用的协议，目前大多数的网站使用的是 HTTP 协议，或者在 HTTP+SSL 组成的 HTTPS。第二个部分是网址，如 www.baidu.com。剩下的部分则指向了服务器上的所要访问的资源。而随着交互式网页应用的网页开发技术 ajax 等技术的兴起，越来越多的网站采用动态 URL 技术，使得互联网上的同一资源，往往有几个不同的 URL。这也使得对于 URL 很多情况下无法对同一资源进行唯一标识。

接着介绍一下 HTTP 的缓存，不同的用户在访问互联网上的同一资源时，服务器会多次传输同一份文件，每次通过网络传输给用户，会消耗大量的网络资源，同时也会造成整个互联网数据的拥塞。所以 HTTP 协议采用了许多与网路缓存相关的技术。让用户缓存一个服务器资源的副本，这样就可以节约许多带宽资源。HTTP 缓存有以下优点：1）减少了网络流量的冗余传输，节约了大量的网络带宽。2）加快了用户的访问速度，可以很快的加载已经进行缓存的页面。3）减少了原始服务器的载荷，使得服务器可以更快地响应用户的请求，也可以避免服务器过载现象的出现。4）降低了整个网络的时延，可以较快地访问较远的资源。

然而，原始服务器中的资源可能随着时间的推移发生改变，这里就提到了一个再验证的概念，其表示用户会不断的对其缓存的副本是否过时进行检测。为了有效的进行副本的再验证，HTTP 也对其定义了一些特殊的请求。其中 HTTP 的条件方法可以高效地进行再验证。HTTP 允许缓存向原始服务器发送一个条件 GET 请求，当原始服务器发现其缓存的副本已经过时，才会向请求端返回一个对象主体。HTTP 一共定义了 5 个条件请求部首，其中和缓存相关的有两条，分别是 If-Modified-Since 和 If-None-Match。

其中 If-Modified-Since 对应的标签是 LastModified，而 If-None-Match 对应的是 Etag 标签，当原始服务器端的资源发生变化时，服务器会返回一个新的资源和该资源的相应的新的 Etag 标签和一个 LastModified 标签。

如图3.2为用户发送第一次请求的流程图，如图3.3为用户再次发送请求。

3.1.4 特征选择

特征选择是一种的数据预处理过程，对于许多高维度空间的样本来说，用大量的特征属性构建机器学习模型会消耗大量资源，所以需要通过特征选择，删除或者合并冗余的特征，选取出尽可能小的特征子集。整个特征选择的框架如图3.4

而特征选择有分为基于搜索策列划分的特征选择方法和基于评价准则划分的特征选择方法。下面我们将详细介绍基于评价准则划分的特征选择方法。基于评价准则划分的特征选择方法有分为过滤式的特征选择方法和包裹式的特征选择方法，其主要的区别在于是否和后续的机器学习算法有关。过滤式的特征选择算法与后续的机器学习算法无关。

过滤式的特征选择算法一般通过一些相关统计量对特征的重要性进行度量，主要采用的的度量标准分为以下几类：距离度量、信息度量、一致性度量和依赖

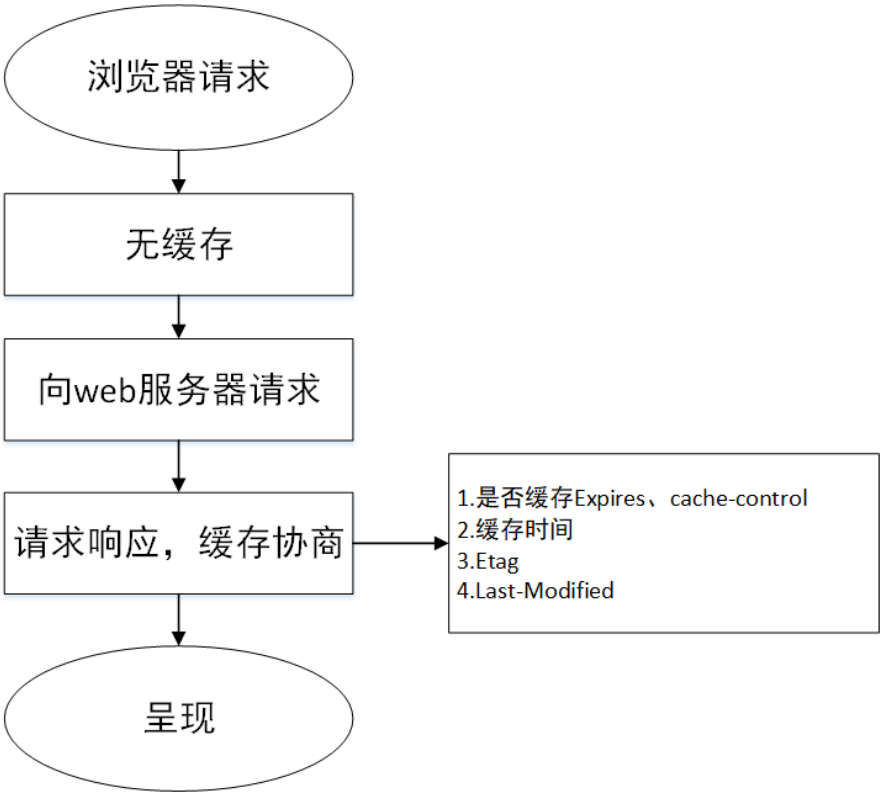


图 3.2 用户发出第一次请求

Figure 3.2 Flowchart of the first request from the user

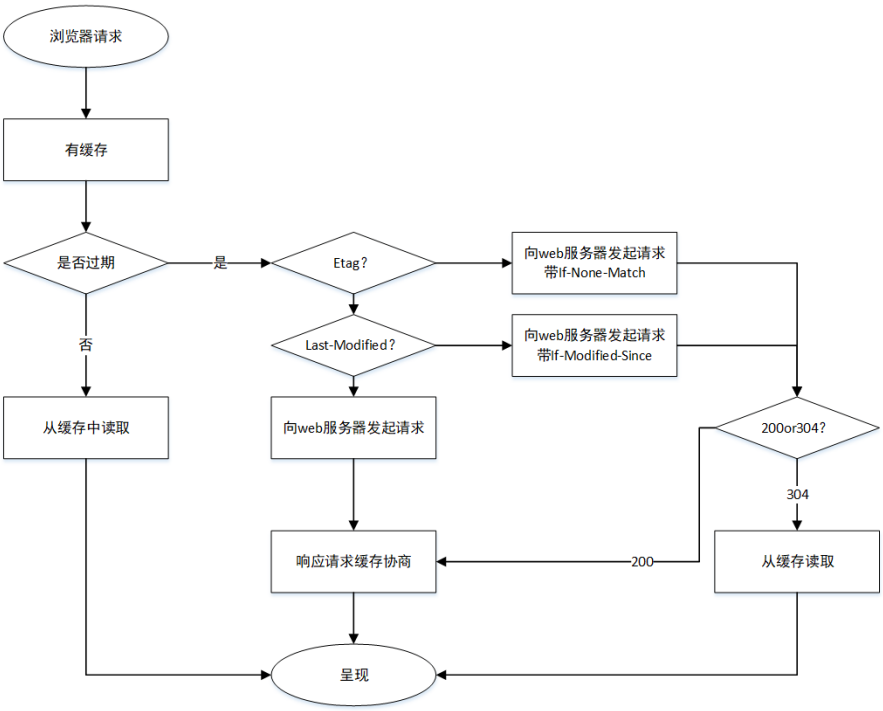


图 3.3 用户再次请求

Figure 3.3 Flowchart of the second request from the user

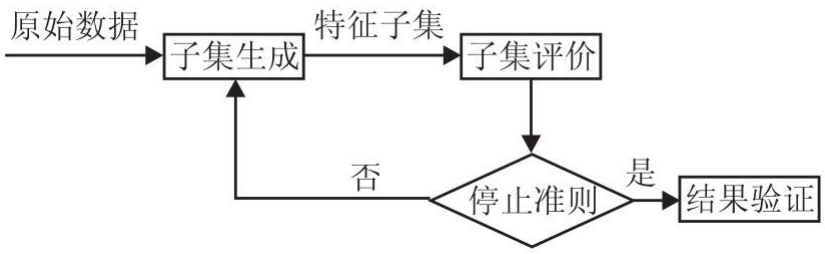


图 3.4 特征选择的框架

Figure 3.4 Framework of feature selection

性度量，而本文主要采用的度量标准是信息度量和依赖性度量。

包裹式的特征选择方法将学习器的最终结果作为评价的重要指标，使整个样本集针对学习器的不同进行更有个性的优化，从而达到特征选择的目的。

3.1.5 信息熵

1948 年著名的学者香农第一次提出信息熵的概念，以解决对不同信息的量化度量问题。香农认为任何信息都会存在不同程度的冗余，只是大小问题。一个信息源的冗余取决于其每个符号（数字、单词或者字母）的不确定性。一般来说，对于一个信号源，其出现不同的符号概率越大，则其熵越大。

下面给出信息熵的公式3.3：

$$H(U) = -\sum_{i=1}^{n} p_i \log_{10} p_i \tag{3.3}$$

其中 U 表示信息源，Pi 表示信息源中每一个符号出现的概率。从机器学习的角度说，一个属性的信息熵反映了该属性所包含的信息量的大小。信息熵越大则说明其包含的信息越多。

3.1.6 互信息

在概率论和数理统计中，两个随机变量之间的互信息表示两个变量之间依赖关系的强弱，而在特征选择中，两个属性之间的互信息也是过滤式的特征选择算法的重要评价标准之一。

而与其它的相关系数不同，互信息并不仅仅局限于实值随机变量，它的值主要由联合分布 p(X,Y) 以及边缘分布的乘积 p(X)p(Y) 所以决定的。互信息度量了两个事件之间的相关性。

根据互信息的定义，两个离散型随机变量 X 和 Y 的互信息可以定义为如下：

$$I(X;Y)=\sum_{y\in Y}\sum_{x\in X}p(x,y)\log_{10}\left(\frac{p(x,y)}{p(x)p(y)}\right) \tag{3.4}$$

其中 p(x,y) 表示 X 和 Y 的联合概率分布函数，而 p(x) 和 p(y) 分别是 X 和 Y 的边缘概率分布函数。

而在两个随机变量是连续型随机变量的情形下，计算互信息的公式被替换成了二重定积分：

$$I(X;Y)=\int_{y}\int_{x}p(x,y)\log_{10}\left(\frac{p(x,y)}{p(x)p(y)}\right)dxdy \tag{3.5}$$

其中 p(x,y) 当表示 X 和 Y 的联合概率密度分布函数，而 p(x) 和 p(y) 分别表示 X 和 Y 的边缘概率密度分布函数。

根据互信息的定义可以看出，互信息表示了两个随机变量 X 和 Y 所共享的信息。例如，如果两个随机变量 X 和 Y 相互独立，则认为随机变量 X 不对 Y 提供任何信息，反之随机变量 Y 也不对 X 提供任何信息，所以它们之间的互信息的值为零。以上的情况，在特征选择中，属性 X 和属性 Y 都将会被保留如果随机变量 X 是 Y 的一个线性的函数关系，同时随机变量 Y 也是 X 的一个线性函数，那么 X 和 Y 传递的所有信息被 X 和 Y 共享，可认为随机变量 X 可以决定 Y 的值，反之亦然。这种情况下随机变量 X 和 Y 的信息熵也是相同的。以上这种情况认为随机变量相互依赖。在特征选择中，会去除属性 X，或者去除属性 Y。

3.2 重复音视频实时检测的挑战

在网络流量中检测重复音视频文件有许多挑战，首先随着用户对音视频内容的音质和清晰度要求的不断提高，音视频文件大小越来越大。使得代理服务器等网络中间件无法存储音视频文件本身，从而无法使用 MD5 等传统的哈希算法对文件重复性进行检测。其次网络中间件所使用的设备其内存、CPU 等资源有限，经常需要在内存集约的情况下工作，因此无法采用较为复杂的方法，所采用的方法应尽量准确高效且准确度较高。

下面我将详细介绍重复音视频实时检测所采用的方法，首先介绍使用传统的机器学习方法对网络流量中的音视频文件的重复性进行预测，接着介绍预测性文件标识生成，通过标识可在音视频传输初始阶段识别重复音视频文件，且消耗的资源较少准确度较高。

3.3 重复音视频文件预测实验

本段将详细介绍使用传统的机器学习方法：决策树，朴素贝叶斯，对真实环境的音视频文件进行了重复性预测，以此来验证机器学习方法的效果。

3.3.1 实验思路

从真实线上环境获取音视频流量，对这些流量进行解析，并获取其报文头部的一些特征，如 Etag，LastModify 等和缓存相关的一些特征、流量内容头部的一些信息。特征提取后，进行特征选择，主要使用的方法是包裹式选择和过滤式选择相结合的方式。同时计算整个音视频流量的流式模糊哈希值，用以标记整个音视频流量的内容。

在机器学习算法的选择上，主要采用了朴素贝叶斯和决策树，其原因主要有以下三点：

一是所获取的特征大多数为标称量，很难对其进行量化，且标称量之间的加减没有数学意义。而决策树和朴素贝叶斯无需对特征进行数学计算，符合特征主要为标称量的条件。

二是朴素贝叶斯和决策树其模型构建完成后，运算量较小，空间复杂度和时间复杂度符合真实环境对算法高效性的需求，而当今较流行的深度学习方法虽然准确度较高，但其需要消耗大量资源，不符合真实环境的需求。

三是由于未对整个的音视频流量进行测量，所以该实验属于探索式的知识发现，决策树算法的特点在于决策树的分类器构建不需要任何领域的知识和参数设定，所以非常适合用于探索式的知识发现，遂选择了决策树算法。

数据集是从国内某公司网关收集的 3 天真实网络流量，共约 450 万条音视频数据，整个实验数据的文件大小分布如图3.5。

其中完整 80% 的数据 297 万条，这里介绍一下什么是完整度。由于现如今大量的音视频网站采用了流媒体技术，而大部分网络用户观看在视频时经常出现快进和后退，从而导致大量音视频文件不完整的情况出现。完整度 = 观看文件长度/实际总文件长度。

更高的文件完整度代表该流量将经过更加彻底的分析，同时由于流式模糊哈希特性的影响，对于完全相同但完整度较低的两个音视频文件，其流式模糊哈希的相似度较低，从而无法判断两个音视频文件是否相似。最终用于实验的数据选择了完整度为 80% 的数据。整个实验数据的完整度 80% 文件分布如图3.6：

数据集标注是将所有音视频文件的哈希值存储到相似性查找系统中，若该

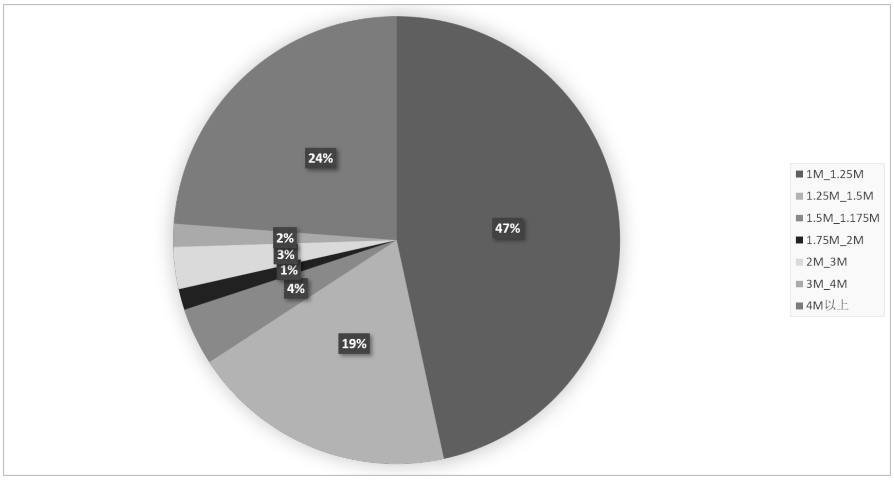


图 3.5 所有音视频大小分布

Figure 3.5 files size distribution

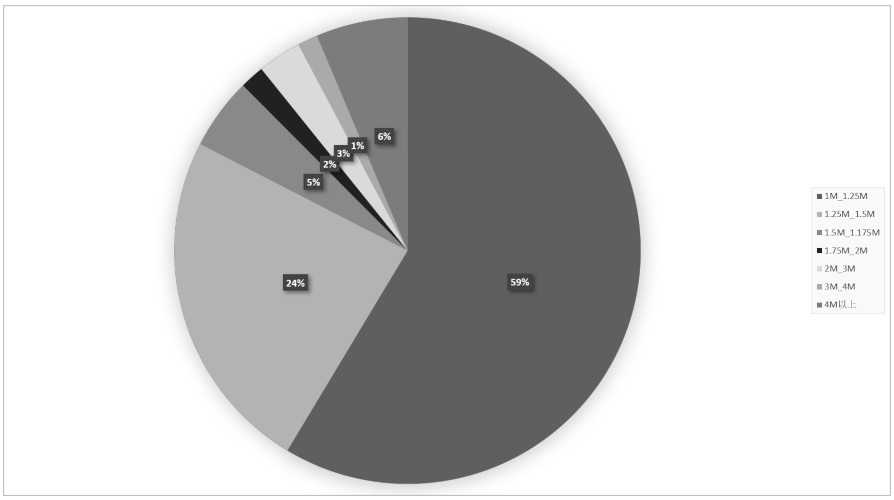


图 3.6 完整度 80% 音视频大小分布

Figure 3.6 files size distribution(file transfer completeness 80%)

哈希值在系统中找到与该流量相似的摘要，则认为其重复，若在系统中找不到与该流量相似的摘要，则认为其不重复。

最后是对选取的特征进行量化处理，选择的特征和其特征量化方式见表3.1：

表 3.1 所选特征和其特征量化方式

Table 3.1 Selected features

HTTP 头部信息	量化方式
URL	n-gram
IP	按 8 位分割
MediaTpye	保留原格式
MediaLen	保留原格式
Etag	CRC32
LastModify	CRC32
观看延迟	观看时间-LastModify

URL 的特征选择采用了 n-gram 的方式，分别尝试了 n=3，4，5，6，7 的情况。考虑到观看视频的 ip 地址和地域之间可能存在的关系，ip 地址采用了 8 位分割。Etag 和 LastModify 采用了 CRC32 加密，作为一个标量信息处理。之所以采用 CRC32 加密是因为使用的机器学习库 sklearn 最多支持 32 位的标称量。最后观看时间是指观看该音视频的时间减去 LastModify 的时间，选取该特征的主要原因是，若间隔时间过长，则视频发生变更的可能性比较大。采用的机器学习库是基于 python 的 sklearn。

3.3.2 实验结果

采用了简单的交叉验证的方式，随机选取 80% 的数据作为训练集，剩下的 20% 的数据作为验证，最终的结果为决策树预测是否重复的准确度为 68%，召回率为 55%。而朴素贝叶斯的准确度为 16%，召回率为 18%。而真实环境对重复音视频文件预测的准确度要求为 99.7%，可见决策树朴素贝叶斯方法无法满足真实环境要求。其原因主要有两点，首先音视频流量报文头部的特征较少，与缓存相关的特征大多数为标称量，很难提供较为有用的信息，其次由于在内存集约的环境下工作，无法对音视频文件头部进行编解码从而获取编解码后视频的帧信息，使得有用的特征大大减少。因此最终采用通过生成音视频文件标识的方式，对文件的重复性进行检测。

3.4 预测性文件标识生成

上文通过重复音视频文件预测实验，对使用机器学习方法来预测网络流量中的音视频文件是否重复进行了探索，其结果证明，决策树和朴素贝叶斯等传统的机器学习方法其预测结果的准确率和召回率并不能符合真实环境的需求。所以需要一种新的方法对在网络流量中的重复音视频文件进行预测。最终决定使用文件标识的方式对重复的音视频文件进行检测。本段将介绍预测性文件标识的生成，在下章将详细介绍基于流式模糊哈希的重复音视频检测方法。

3.4.1 思路

在音视频流量刚刚建立传输开始时，选取音视频流量头部的如 Etag，Last-Modify 等和缓存相关的一些特征，以及流量内容头部的一些信息，再进行动态的特征筛选，最后通过 MD5 等加密算法生成一个具有预测性的文件标识。

3.4.2 生成音视频文件标识的难点

而面向网络流量的音视频文件标识生成的难点主要又以下两点：

难点一：音视频流量复杂，每种音视频流量其特征也不完全相同。由于一些原始服务器并不支持 HTTP 缓存，有些音视频流量并不含有 Etag 和 LastModfy 等特征，这对音视频流量的特征选取增加了许多挑战。

难点二：如何建立一套行之有效的音视频流量特征评价体系，量化的评价特征的效果？

因此我们需要有一套行之有效的机制来对生成标识的特征效果进行评估。

3.4.3 特征选择评价标准

主要的思路是采用过滤式的特征选择方式，其原因主要有以下两点：一是包裹式选择方式需要训练学习器，使用机器学习方法，但根据上文的实验传统的机器学习方法无法满足真实环境要求，所以无法使用包裹式的选择方法。二是选取的音视频流量头部特征多为标称量，而过滤式的选择方式其许多评价标准可以适用于对标称量的评价，符合使用环境。

接着介绍过滤式的特征选择方式用什么度量方法，首先选择的是信息熵，前文已经提到过，信息熵表示一个属性的随机性，信息熵越大表明该属性随机性越强，包含的信息越多。第二个选择是互信息，互信息表示两个属性之间的依赖关系的强弱，使用互信息的目的是降低属性的维度，减少获取的属性的数量，选取的属性其之间的互信息越小越好。

3.4.4 实验数据

实验所用的数据集是从国内某公司网关收集的 3 天真实网络流量，共约 450 万条音视频数据，其中完整 80% 的数据 297 万条，一共包含 15 个特征，分别包含了 URL，ServerIP，LastModified，Etag，MediaLen，MediaType，音视频文件头部内容 1k 一直到 32k（已经通过 MD5 进行加密）。具体的特征如表3.2所示：

表 3.2 数据集特征

Table 3.2 Dataset Features

特征	描述
URL	统一资源定位符
ServerIP	服务器 IP
LastModified	LastModified 标识
Etag	Etag 标识
MediaLen	音视频文件的长度
MediaType	音视频文件的格式
1k、2k、4k…..32k（6 个)	音视频文件头部 nK 的 MD5 值
SFH	流式模糊哈希值
SFH_len	流式模糊哈希值长度

3.4.5 音视频特征信息熵和互信息

首先是信息熵的计算，计算了所有特征的信息熵。由于单向流的影响，许多音视频流量无法获取 URL，其 URL 特征记为 None。最后的信息熵计算实验结果如表3.3所示：URL 这一特征其熵之所以非常低，是因为由于捕获环境的单向流

表 3.3 特征信息熵结果

Table 3.3 Features Information Entropy Results

特征	信息熵	特征	信息熵
视频文件头部内容 32K	14.47	Etag	14.19
音视频文件头部内容 16K	14.42	LastModify	13.69
音视频文件头部内容 8K	14.38	MediaLen	12.17
音视频文件头部内容 4K	14.36	URL	10.57
音视频文件头部内容 2K	14.34	ServerIP	7.17
音视频文件头部内容 1K	14.32	MediaType	1.9

影响，大量的音视频流量是源服务器的应答流量无法获取 URL，大部分的 URL 特征为 None，从而导致 URL 的熵较低。

由于互信息的计算较为复杂，因此从原始的数据集中随机抽取了 50 万条完整度 80% 以上的音视频数据，而参与互信息计算的特征只有 Etag、LastModify、MediaLen、URL 和 ServerIP 一共 5 个特征。其原因如下：

1）以上 6 个特征其信息熵较高，可见其含有的信息量较大。

2）对于不同长度的音视频文件内容头部，根据常识，其应有较强的相关性。所以只选取了信息熵最大的一个。

最后互信息的计算结果如表3.4所示 根据互信息的结果，Etag 和 LastModify

表 3.4 特征互信息结果

Table 3.4 Features mutual information result

特征	互信息	特征	互信息
Etag，LastModify	0.94	LastModify，URL	0.24
Etag，MediaLen	0.42	LastModify，ServerIP	0.35
Etag，URL	0.25	MediaLen，URL	0.37
Etag，ServerIP	0.34	MediaLen，ServerIP	0.39
LastModify，MediaLen	0.42	URL，ServerIP	0.23

的相关性较强，而目前许多老旧的服务器并不支持 HTTP 缓存，因此可能不含有 Etag 或者 LastModify 标签，根据互信息的实验可知，Etag 和 LastModify 标签可以相互代替，选择其中一个即可。

3.4.6 预测性文件标识生成

根据上文的实验，一共选取了 Etag、LastModify、MediaLen、URL、ServerIP 五个特征作为计算音视频文件标识的基础，同时改变选取的音视频文件内容长度 nk 生成 6 个不同的文件标识。在下章我们将对这些文件标识的效果进行评估，最后选取一个合适的文件标识。

3.5 小结

本章首先介绍了决策树、朴素贝叶斯、和 HTTP 缓存相关的背景知识。

接着详细介绍了重复音视频文件预测实验，在重复音视频文件预测实验中对使用机器学习方法来预测网络流量中的音视频文件是否重复进行探索，最终

的结果为决策树和朴素贝叶斯等传统的机器学习方法其预测结果的准确率和召回率并不能符合真实环境的需求。

最后介绍了预测性文件标识的生成的思路，选取音视频流量头部的一些特征生成一个具有预测性的文件标识，并通过熵和互信息对生成标识的特征进行筛选，最后生成了 6 个不同的文件标识，在下章我们将对这些文件标识的效果进行评估。

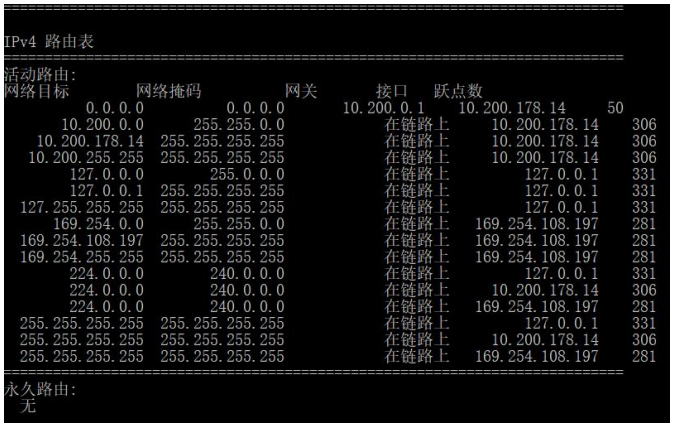
第 4 章　基于流式模糊哈希的重复音视频检测方法

本章将首先介绍相关背景知识，接着介绍了基于流式模糊哈希的重复音视频检测方法和如何生成文件编号，之后详细介绍评价标识所采用的标准并计算误报率，漏报率的步骤，最后通过实验证明了预测性音视频文件标识的效果。

4.1　背景知识

4.1.1　单向流

在介绍单项流之前先介绍什么是网络路由，网络路由是指分组从源到目的地时，决定端到端路径的网络范围的进程。路由工作在 OSI 参考模型第三层——网络层的数据包转发设备。路由器通过转发数据包来实现网络互连。路由器通常连接两个或多个由 IP 子网或点到点协议标识的逻辑端口，至少拥有 1 个物理端口。路由器根据收到数据包中的网络层地址以及路由器内部维护的路由表决定输出端口以及下一跳地址，并且重写链路层数据包头实现转发数据包。路由器通过动态维护路由表来反映当前的网络拓扑，并通过网络上其他路由器交换路由和链路信息来维护路由表。如图4.1为典型的 Windows 路由表



IPv4 路由表

活动路由:

网络目标	网络掩码	网关	接口	跃点数
0.0.0.0	0.0.0.0	10.200.0.1	10.200.178.14	50
10.200.0.0	255.255.0.0	在链路上	10.200.178.14	306
10.200.178.14	255.255.255.255	在链路上	10.200.178.14	306
10.200.255.255	255.255.255.255	在链路上	10.200.178.14	306
127.0.0.0	255.0.0.0	在链路上	127.0.0.1	331
127.0.0.1	255.255.255.255	在链路上	127.0.0.1	331
127.255.255.255	255.255.255.255	在链路上	127.0.0.1	331
169.254.0.0	255.255.0.0	在链路上	169.254.108.197	281
169.254.108.197	255.255.255.255	在链路上	169.254.108.197	281
169.254.255.255	255.255.255.255	在链路上	169.254.108.197	281
224.0.0.0	240.0.0.0	在链路上	127.0.0.1	331
224.0.0.0	240.0.0.0	在链路上	10.200.178.14	306
224.0.0.0	240.0.0.0	在链路上	169.254.108.197	281
255.255.255.255	255.255.255.255	在链路上	127.0.0.1	331
255.255.255.255	255.255.255.255	在链路上	10.200.178.14	306
255.255.255.255	255.255.255.255	在链路上	169.254.108.197	281

永久路由:

无

图 4.1 路由表

Figure 4.1 route table

路由的不对称性在整个网络中是普遍存在的。对于每个网络上的节点，会根据当前网络的情况和目的 IP 独立地选择不同的路由路径，但由于多条等价路由或者负载均衡等因素的影响，路由的不对称性是一种无法避免的现象。如果两个端点之间传输的数据包其上行和下行之间的物理链路是相同的（即经过网络转

发设备顺序是逆序相等的），则它们是路由对称的。否则路由称为不对称。而在物理链路上只能观察到上行或者下行数据包的网络流，称之为单向流。单向流是不对称流量的一种，通常对单向流下行数据包的处理无法获取其访问的 URL 等信息。

4.1.2 流式模糊哈希相似的不足

上文提到了流式模糊哈希采用存储中间计算结果的方法进行流式数据摘要计算，能够处理数据缺损、乱序和重叠的情况，并且采用伽罗华域（Galois Field）的乘法运算作为强哈希算法减少内存占用，使得本算法能够在内存集约的情况下实时计算流式数据摘要。但流式模糊哈希值有一定的缺陷性。

首先由于网络中音视频流量的不完整传输，流式模糊哈希值计算的音视频文件的完整度往往较低，无法对完整度较低的文件进行彻底的分析。

其次流式模糊哈希值之间的相似不具有传递性。举个例子，H1，H2，H3 分别是同一个音视频文件的模糊哈希值，但由于用户的观看习惯，它们分别对应的完整度不同，分别是 80%，100% 和 80%。H1 和 H2 相似，H2 和 H3 相似，但 H1 和 H3 不相似。其原理是因为 H1 和 H3 的两个音视频文件完整度较低，导致其编辑距离较低。

该特性对下面介绍的文件编号的计算和漏报误报的统计产生了巨大的影响。

4.2 基于流式模糊哈希的重复音视频检测方法

上文提到了预测性文件标识的生成，那如何对重复音视频进行检测呢？步骤如下，在音视频传输刚刚建立时，生成音视频文件标识，若该标识在数据集中可查询，则认为该音视频文件已经重复出现，若该音视频文件重复，则告知内容分析模块无需继续进行内容审计，若该标识未能在数据集中查询，则认为不重复。数据库记录该音视频文件的标识和内容分析模块的审计结果。整个思路的具体流程如图4.2所示。

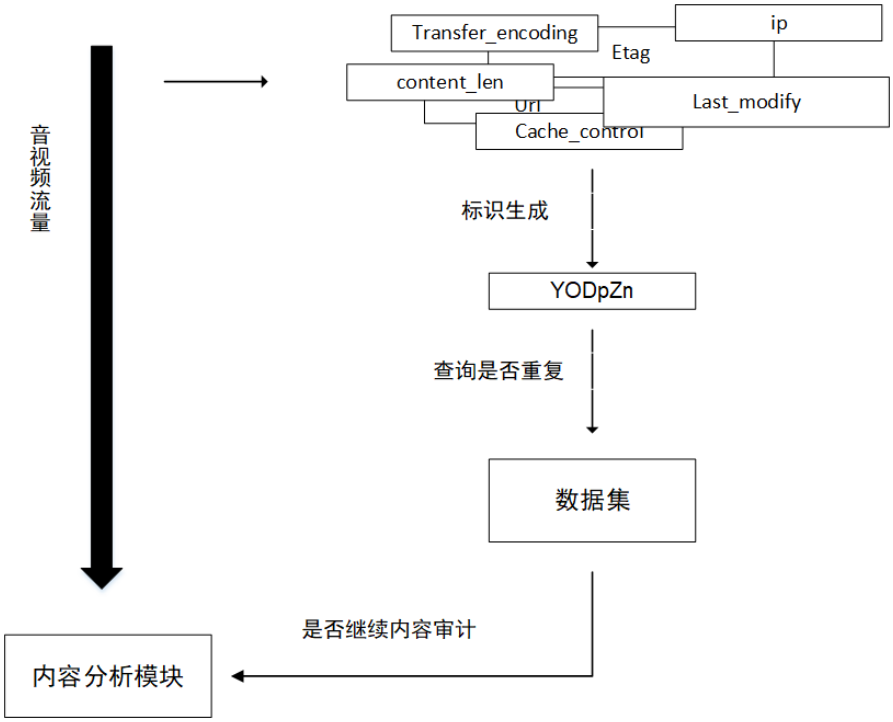


图 4.2 基于流式模糊哈希的重复音视频检测方法流程图

Figure 4.2 Flow chart of Repeated audio and video detection method

4.3 音视频文件编号

在介绍整个预测性文件标识的评价体系前，先要介绍一下文件编号的生成，文件编号是一个基准值，对于同一个文件其文件编号相同，文件编号由流式模糊哈希值生成。接着，介绍一下文件编号计算的思路：主要是通过流式模糊哈希，将相似的音视频文件赋予相同的文件编号，前文提到过流式模糊哈希的相似不具有传递性，因此需要选出一个合适的流式模糊哈希值作为基准。例如在上文提到的例子若以 H1 和 H3 作为基准模糊哈希值，则会出现两个不同的音视频文件编号。若以 H2 作为基准模糊哈希值，则只出现唯一的音视频文件编号。因此，应首先需要找到一个基准的流式模糊哈希值，再对文件进行编号。

基准的哈希值应为完整度最高的音视频流量所生成的哈希值。若完整度最高的基准流量摘要存在多条，则选取与其他流量相似度之和最高的哈希值。

下面是计算文件编号的具体步骤如下：

步骤一：将该段时间产生的所有音视频流量的模糊哈希值存入基于流式模糊哈希的相似性查找系统，n=1。

步骤二：获取第 n 条哈希值，若发现其已经有音视频标识则 n=n+1，再次执行步骤二，否则执行步骤三。

步骤三：将第 n 条哈希值在系统中查询，获取所有相似的音视频，并在这些相似的音视频中获取基准流式模糊哈希值，再次查询该基准流式模糊哈希值，其结果打上音视频标识 n。n=n+1，若为最后一条执行结束计算，否则执行步骤二。

如图4.3为整个音视频文件编号的流程图

文件编号在标识准确性评价中起到了重要的作用，在下文中我将详细介绍。

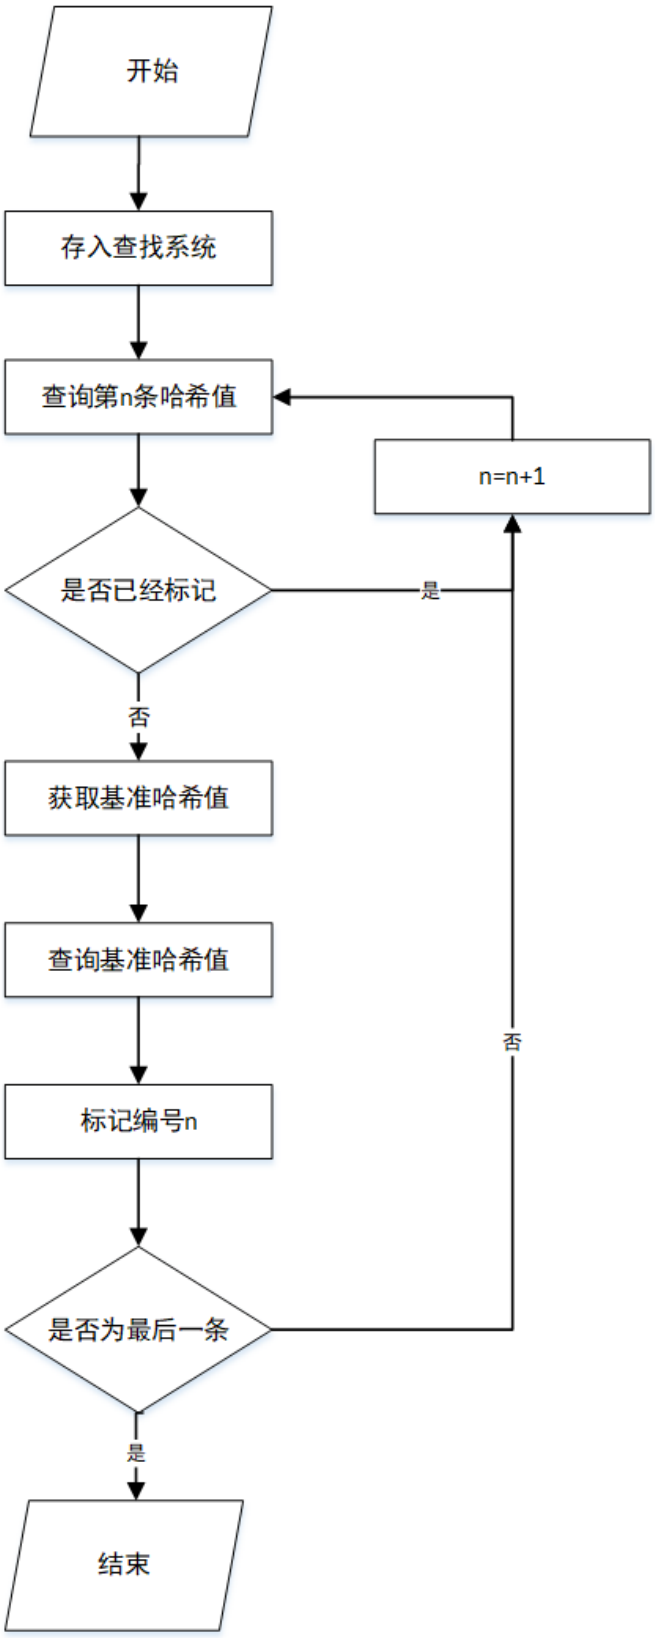


图 4.3 音视频文件编号流程图

Figure 4.3 Audio and video file number generate

4.4 预测性文件标识评价

上章中一共生成了 6 个不同的文件标识，那么如何对文件标识的效果进行评价？

我们采用基于流式模糊哈希值的方法，主要采用了两个评价指标：一是漏报率，漏报率 = 漏报的音视频文件数/总音视频文件数。这里的漏报是指：其预测性文件标识不相同，但文件编号相同。二是误报率，误报率 = 误报的音视频文件数/总音视频文件数。这里的误报是指：其预测性文件标识相同，但文件编号不同。由于代理服务器等网络中间件有着色情检测、版权保护的作用，因此对于重复音视频文件检测系统来说，其误报率要比漏报率重要。同时误报率的提高必来带来漏报率的降低，反之亦然。

4.5 实验

主要做了两个实验，实验一：计算预测性文件标识的误报率，实验二：计算标识的漏报率。

4.5.1 实验一

首先生成了所有音视频数据的文件编号，接着计算不同的 6 个文件标识的误报率，误报的定义是其预测性文件标识相同，但文件编号不同，其结果如表4.1 可见当音视频文件头部内容 32k，生成预测性文件标识，误报率为 0.34%，符合

表 4.1 误报率结果

Table 4.1 Results of false positive rate

特征	0k	1k	2k	4k	8k	16k	32k
误报率	0.168	0.074	0.032	0.014	0.008	0.0039	0.0034

真实环境要求对误报率的要求。而随着获取的音视频文件头部的长度越来越长，其误报率也成下降趋势，也验证了随着熵的增高，其特征的效果越好的设想，因此信息熵是一种较好的评价文件标识的标准。

4.5.2 实验二

接着计算音视频文件标识的漏报率，其结果如表4.1 4.1 可见随着获取的音视频文件头部的长度越来越长，其漏报率也成下降趋势，但下降的不明显，当文件头部内容长度已经达到 32k，但其漏报率依旧高达 62%，这又是什么原因呢？

表 4.2 漏报率结果

Table 4.2 Results of Missing rate

特征	0k	1k	2k	4k	8k	16k	32k
漏报率	0.67	0.66	0.65	0.66	0.66	0.65	0.62

通过对漏报数据的观察发现，大量的漏报数据其流量中 Etag 和 LastModified 标签相同，主要其 ServerIP 地址不同。本文上章提到过，由于真实环境单向流的影响，很多音视频流量无法获取其 URL，或者获取 URL 的开销极大，是否可以去除 URL。再次很多网站式 URL 是动态生成的，其不同的 URL 会标记相同的视频资源。

为了了解漏报率产生的原因，同时满足真实环境的需求，重新生成了三个音视频标识，并计算其漏报率，三个标识分别是：去除 ServerIP 的文件标识，去除 url 的标识，和同时去除 URL 和 ServerIP 的标识，三个标识的音视频文件头部长度都为 32k。实验结果如表4.3所示：

表 4.3 预测性文件标识漏报率实验结果

Table 4.3 Predictive Document Identification Missing Rate Experimental Results

特征	漏报率	漏报率
去除 ServerIP 的文件标识	0.32%	10%
去除 URL 的文件标识	0.37%	60%
去除 ServerIP 和 URL 的文件标识	0.35%	7%

可见 ServerIP 对漏报率的影响巨大,生成预测性文件标识时不应该把 ServerIP 作为候选特征，这样可以有效降低标识的漏报率，也不会导致误报率的激增。同时，去除 URL 时其误报率也未有明显降低，而去除 ServerIP 和 URL 的文件标识可以大大减少整个系统在单向流对准上的开销。

4.6 小结

本章首先介绍了单向流相关的背景知识

接着指出了流式模糊哈希不具有传递性以及其对文件编号计算的影响。

最后介绍了基于流式模糊哈希的重复音视频检测方法，提出了两个标识的评价标准漏报率和误报率，并介绍了误报率和漏报率的计算过程。最后对预测性文件标识的效果进行了验证，该方法符合真实环境的需求，并指导了预测性文件

标识的生成。

第 5 章　系统设计与实现

本章节将介绍整个面向网络流量的重复音视频实时检测系统，包括系统的概述和功能测试。

5.1　系统概述

由于本文提出的系统是面向网络流的，因此本系统的输入是在线的网络流量。整个系统由两个部分组成，重复音视频文件实时检测方法和预测性文件标识准确性评价，整个系统的实现框架图如图5.1所示：

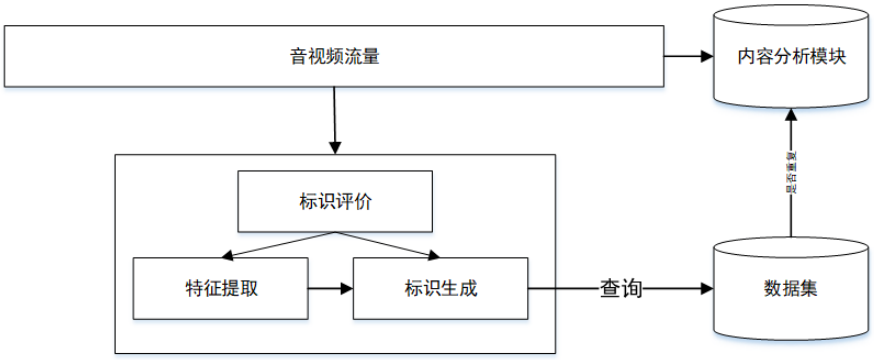


图 5.1 面向网络流量的重复音视频实时检测系统框架图

Figure 5.1 audio and video duplicated files detection system framework

当音视频流量传输时，该系统选取音视频流量头部的如 Etag，LastModify 等和缓存相关的一些特征，和流量内容头部的一些信息，最后通过 MD5 等加密算法生成一个具有预测性的文件标识，若该文件标识在数据集中可查询，则认为该音视频文件是重复的，若该文件标识未能在数据集中查询，则认为文件不重复，内容分析模块继续分析，且数据集记录该音视频文件的标识和内容分析模块的分析结果。

而预测性文件标识准确性评价则采用一种半离线的方式，系统会定期抽取真实流量的 10% 作为测试集，并记录他们的流式模糊哈希值，对文件标识的误报率和漏报率进行检测。

5.2 系统的功能测试结果

实验环境是在真实环境，对音视频流量进行复制，流量副本通过整个重复音视频文件实时检测系统，并与原始流量进行对比。

首先对有害音视频文件召回率进行了检测，在真实环境的内容分析模块返回的有害音视频文件数进行了对比，以检测整个重复音视频文件实时检测系统对内容分析模块的影响。其结果如表5.1: 可见，重复音视频文件实时检测系统并

表 5.1 内容分析模块有害音视频文件召回数

Table 5.1 harm audio and video file recall

完整度	有害音视频文件召回率
80%	99.4%
95%	94.7%

没有对内容分析模块的有害文件召回率有很大影响。接着又对整个系统的功能进行了测试其结果如下：

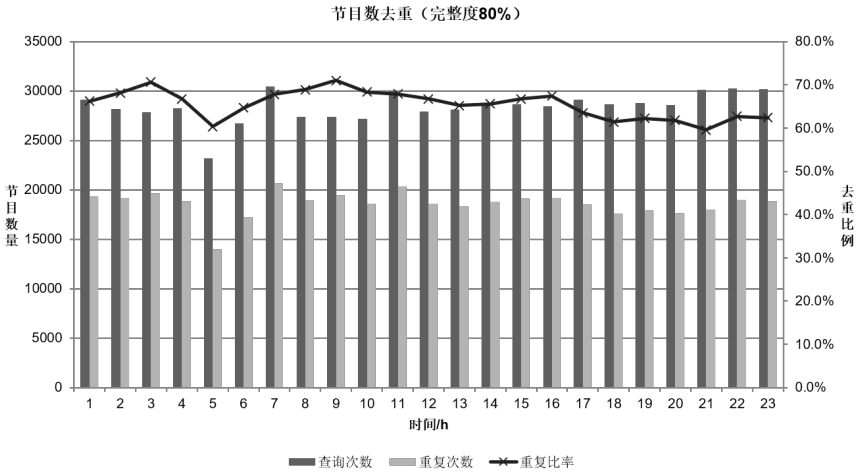


图 5.2 完整度 80% 文件数去重

Figure 5.2 Deduplication rate by file number(file transfer completeness 80%)

如图5.2，完整度 80% 的文件数平均的去重率约为 65%，文件数的去重率 = 发现的重复文件数/总文件数。如图5.3完整度 95% 的文件数平均的去重率约为 59%。如图5.4完整度 80% 的文件的带宽去重率约为 22%，文件带宽的去重率 = 去重后带宽/未去重带宽。如图5.5完整度 95% 的文件数平均的去重率约为 21.4%。

之所以带宽的去重率要远远低于文件的去重率是因为整个系统采用了并行的结构，内容分析模块和重复音视频文件检测是同时进行的。因此，当发现该文

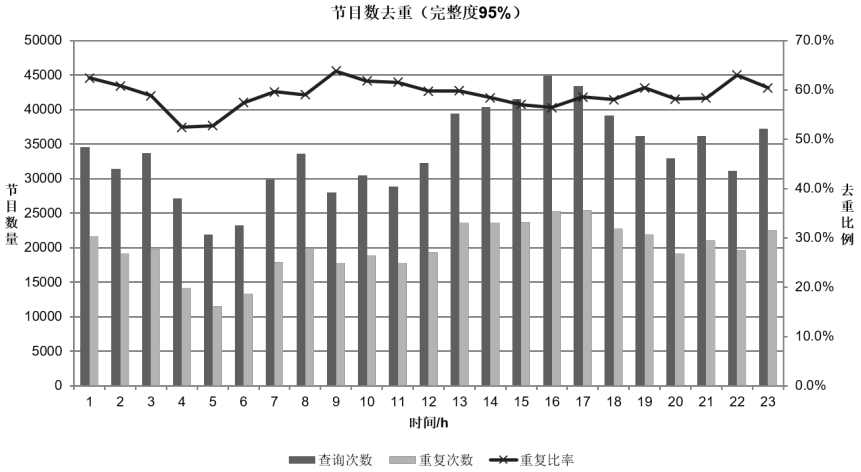


图 5.3 完整度 95% 文件数去重

Figure 5.3 Deduplication rate by file number(file transfer completeness 95%)

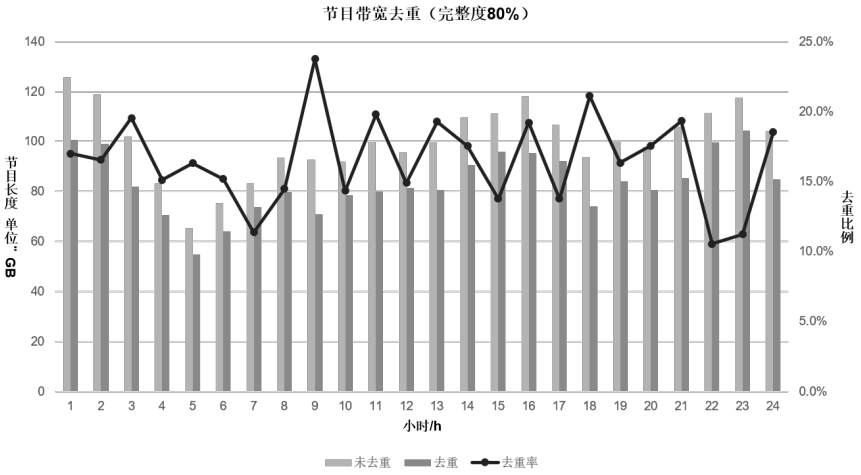


图 5.4 完整度 80% 文件带宽去重

Figure 5.4 Deduplication rate by file size(file transfer completeness 80%)

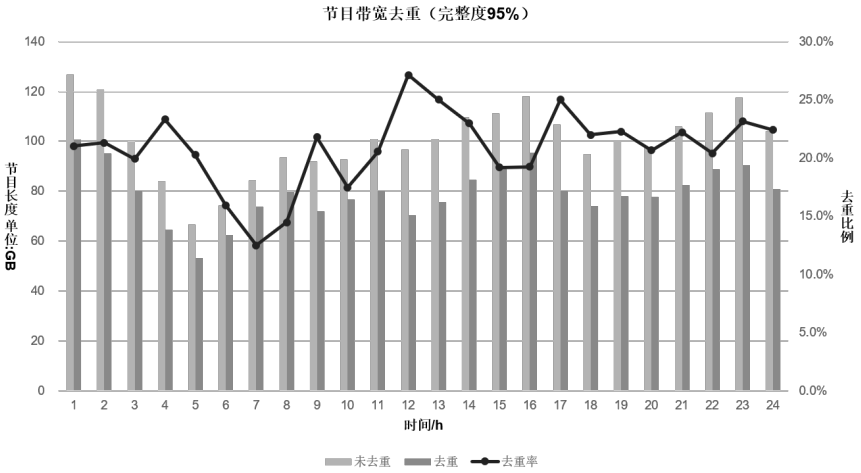


图 5.5 完整度 95% 文件带宽去重

Figure 5.5 Deduplication rate by file size(file transfer completeness 95%)

件重复时，已经审计了部分音视频文件的头部内容，造成带宽的大大提升。

5.3 小结

本章首先介绍了整个重复音视频文件实时检测系统的概述，并对该系统对有害音视频文件的召回率和功能进行了测试。其结果为文件数去重率约为 20%以上，带宽去重率约为 60%。而整个系统对有害音视频文件的召回率并没有明显的影响

第 6 章　总结与展望

前面的章节详细介绍了开展本论文的背景与意义、国内外研究现状、面向网络流量的重复音视频文件实时检测系统的两个关键技术以及整个系统的设计和实现，本章将对以上研究内容进行一次全面的总结，并对研究过程中没有考虑过的问题进行详细分析，并对下一步研究工作做出合理地展望。

6.1　全文总结

随着音视频流量的在网络流量中的占比不断提高，对音视频流量的重复性检测也越来越受到广泛关注。大量的音视频文件通过网络进行传输，这些音视频流量中存在重复，而代理服务器、入侵检测系统等网络中间件需要对这些重复的流量进行处理，以达到版权保护、色情检测等目的，但对这些网络中间件对于重复音视频流量的处理消耗了大量资源。因此需要对重复的音视频文件进行实时检测，以减少这些网路中间件的资源开销。

在学术界，有大量的工作研究网络冗余发现，用以减少整个网络环境的资源开销。

面向数据链路层的网络冗余发现系统，由于数据链路层有以下两个特点：一是由于网路的不稳定性，会出现大量的帧丢失的现象。二是在无线局域网的数据包中包含大量管理和控制帧，导致 IP 数据的比例下降。以上两个特点导致了网络冗余发现系统的效果在数据链路层大大降低。

面向网络层的网络冗余发现系统，大部分的系统是基于端到端的模型，通过不同的网络冗余发现算法对流量的冗余进行检测，其中较为出名的算法是 PACK、MODP 和拉宾指纹。

面向应用层的网络冗余发现系统，其主要应对不同的应用场景如移动设备、企业内部网络、云计算等。

接着介绍了我的两个工作基础，分别是流式模糊哈希和基于流式模糊哈希的大规模相似性查找系统，流式模糊哈希主要用于在网络流量中生成音视频文件的摘要。而相似性查找系统主要是为了查询相似的流式模糊哈希值从而生成音视频文件的编号。

接着介绍整个系统主要基于的两个技术：1）预测性文件标识生成方法。该技术采用信息熵和互信息作为评价标准，对生成文件标识的特征进行筛选，并在

流量建立连接时，生成一个具有预测性的文件标识。2）基于流式模糊哈希的重复音视频检测方法。若文件标识在数据库中可查询，则认为该音视频文件是重复的，同时通过流式模糊哈希值生成文件编号，以验证文件标识的效果，其结果可用于指导文件标识的特征选择。在最后，对整个系统的进行了功能测试。

本文研究的面向网络流的 APP 文件识别关键技术完成以下创新：

1）针对网络流量中重复音视频早期检测难的问题，提出了一种预测性文件标识生成方法，该方法在音视频传输初始阶段识别重复音视频文件。

2）针对重复音视频早期检测效果评估优化的问题，提出了一种基于流式模糊哈希的重复音视频检测方法，该方法可以检测完整的音视频文件的重复性，检测结果可用于指导早期检测方法的特征选择优化。

3）基于上述技术实现了重复音视频实时检测系统，真实网络环境实验结果表明，该系统可在音视频文件传输初始阶段检测其重复性。

6.2 研究展望

本文研究的是面向网络流量的重复音视频文件实时检测系统，处理的对象是在网络中传输的音视频文件，整个系统的研究基于两个技术：1）预测性文件标识生成方法。2）基于流式模糊哈希的重复音视频检测方法。

本文的研究工作存在以下几个方面需要进一步完善：

1）对于不同的标识，设计的生命周期为 24 小时，而对于不同的标识，是否可以生成不同的生命周期，从而减少整个系统的开销。

2）同时目前整个系统对于不同的流量的标识生成，并非动态，需要一个动态的音视频文件标识生成方式，以应对复杂的网络流量和概念漂移。

3）同时基于流式模糊哈希的大规模相似性查找系统的查找速度较慢，且耗费的内存较高，无法在内存集约的环境下使用。

参考文献

CNNIC. 中国互联网络发展状况统计报告[R/OL]. 2018. http://www.cac.gov.cn/2018-08/20/c_1123296882.htm.

TECHNIQUES D D. 重复数据删除技术[J/OL]. 2010, 21(5):916-929. DOI: 10.3724/SP.J.1001.2010.03761.

AGGARWAL B, AKELLA A, ANAND A, et al. EndRE : An End-System Redundancy Elimination Service for Enterprises[J].

AGGARWAL B, AKELLA A, ANAND A, et al. Endre: An end-system redundancy elimination service for enterprises.[J]. 2010.

ANAND A, MUTHUKRISHNAN C, AKELLA A, et al. Redundancy in network traffic: findings and implications[J/OL]. Proceedings of SIGMETRICS/Performance'09, 2009:37-48. http://portal.acm.org/citation.cfm?id=1555355. DOI: 10.1145/1555349.1555355.

ANAND A, MUTHUKRISHNAN C, KAPPES S, et al. Cheap and large cams for high performance data-intensive networked systems[J]. 2010.

CAO Y, LI S, WIJMANS E. (Cross-) Browser Fingerprinting via OS and Hardware Level Features[J/OL]. Proceedings of Network & Distributed System Security Symposium (NDSS), 2017 (March). DOI: 10.14722/ndss.2017.23152.

CHEN J, WEAVER N, WAN T. Host of Troubles : Multiple Host Ambiguities in HTTP Implementations[J/OL]. Ccs, 2016:1516-1527. DOI: 10.1145/2976749.2978394.

CHEN Y, HE W, HUA Y, et al. CompoundEyes: Near-duplicate detection in large scale online video systems in the cloud[J/OL]. Proceedings - IEEE INFOCOM, 2016, 2016-July. DOI: 10.1109/INFOCOM.2016.7524429.

CHUNG J W, CLAYPOOL M. Silhoue e ⁻Identifying YouTube Video Flows from Encrypted Tra ic[J]. Nossdav 2018, 2018.

CISCO. visual-networking-index-vni[R/OL]. 2018. https://www.cisco.com/c/en/us/solutions/collateral/service-provider/visual-networking-index-vni/white-paper-c11-741490.html.

FENG D. Smart In-Network Deduplication for Storage-aware SDN[J]. :509-510.

FENG Q, HUANG J, ERMAN J, et al. How to reduce smartphone traffic volume by 302013.

GE X, LIU Y, DU D H, et al. OpenANFV[J/OL]. Proceedings of the 2014 ACM conference on SIGCOMM - SIGCOMM '14, 2014:353-354. http://dl.acm.org/citation.cfm?doid=2619239.2631426. DOI: 10.1145/2619239.2631426.

HALEPOVIC E, GHADERI M, WILLIAMSON C. On the performance of redundant traffic elimination in WLANs[J/OL]. IEEE International Conference on Communications, 2012:5434-5439. DOI: 10.1109/ICC.2012.6364592.

HALEPOVIC E, GHADERI M, WILLIAMSON C. On the performance of redundant traffic elimination in wlans[C]//IEEE International Conference on Communications. 2013.

HAO Y, MU T, HONG R, et al. Stochastic multiview hashing for large-scale near-duplicate video retrieval[J]. IEEE Transactions on Multimedia, 2016, PP(99):1-1.

HAO Y, MU T, HONG R, et al. Stochastic Multiview Hashing for Large-Scale Near-Duplicate Video Retrieval[J/OL]. IEEE Transactions on Multimedia, 2017, 19(1):1-14. DOI: 10.1109/TMM.2016.2610324.

HUA Y, XIAO B, LIU X. NEST: Locality-aware approximate query service for cloud computing[J/OL]. Proceedings - IEEE INFOCOM, 2013:1303-1311. DOI: 10.1109/INFCOM.2013.6566923.

KORNBLUM J. Identifying almost identical files using context triggered piecewise hashing[J/OL]. Digital Investigation, 2006, 3(SUPPL.):91-97. DOI: 10.1016/j.diin.2006.06.015.

LEI Y, SAPRA K, SHEN H, et al. Cooperative end-to-end traffic redundancy elimination for reducing cloud bandwidth cost[J]. 2013.

LI J, CHENG K, WANG S, et al. Feature Selection: A Data Perspective[J/OL]. ACM Computing Surveys, 2017, 50(6):1-45. DOI: 10.1145/3136625.

LI S, SCHLIEP M, HOPPER N. Facet: Streaming over Videoconferencing for Censorship Circumvention.[J/OL]. Wpes, 2014:163-172. http://dl.acm.org/citation.cfm?doid=2665943.2665944{%}0Ahttp://doi.acm.org/10.1145/2665943.2665944{%}5Cnpapers3://publication/doi/10.1145/2665943.2665944.

LUMEZANU C, GUO K, SPRING N, et al. The effect of packet loss on redundancy elimination in cellular wireless networks[J/OL]. Proceedings of ACM IMC, 2010(January):294. http://dl.acm.org/citation.cfm?id=1879141.1879179. DOI: 10.1145/1879141.1879179.

LUMEZANU C, GUO K, SPRING N, et al. The effect of packet loss on redundancy elimination in cellular wireless networks[J]. 2010.

MA J, SAUL L K, SAVAGE S, et al. Beyond Blacklists : Learning to Detect Malicious Web Sites from Suspicious URLs[J/OL]. World Wide Web Internet And Web Information Systems, 2009:1245-1253. http://portal.acm.org/citation.cfm?id=1557153. DOI: 10.1145/1557019.1557153.

MOGUL J C, CHAN Y M, KELLY T. Design, implementation, and evaluation of duplicate transfer detection in HTTP[J]. Proceedings of USENIX NSDI, 2004(March):4.

MOHAMMAD R M, THABTAH F, MCCLUSKEY L. Phishing Websites Features[J/OL]. Ieee, 2013(May):1-7. papers3://publication/uuid/6A553382-D05D-48FA-97AA-382C3203BB1F. DOI: 10.13140/RG.2.1.2595.6000.

REED A, KLIMKOWSKI B. Leaky Streams[J]. 2016:1114-1119.

REED A, KRANCH M. Identifying HTTPS-Protected Netflix Videos in Real-Time[J/OL]. Proceedings of the Seventh ACM on Conference on Data and Application Security and Privacy - CODASPY '17, 2017:361-368. http://dl.acm.org/citation.cfm?doid=3029806.3029821. DOI: 10.1145/3029806.3029821.

RHEA S C, LIANG K, BREWER E. Value-Based Web Caching[J]. 2003(May).

RIMMER V, PREUVENEERS D, JUAREZ M, et al. Automated Website Fingerprinting through Deep Learning[J/OL]. 2017. http://arxiv.org/abs/1708.06376{%}0Ahttp://dx.doi.org/10.14722/ndss.2018.23105.

SAHOO D, LIU C, HOI S C H. Malicious URL Detection using Machine Learning: A Survey [J/OL]. 2017:1-21. http://arxiv.org/abs/1701.07179.

SANADHYA S, SIVAKUMAR R, KIM K H, et al. Asymmetric Caching: Improved Network Deduplication for Mobile Devices[J/OL]. Mobicom, 2012:161. http://dl.acm.org/citation.cfm?id=2348565{%}5Cnhttp://dl.acm.org/citation.cfm?doid=2348543.2348565. DOI: 10.1145/2348543.2348565.

SANDVINE. 2018-internet-phenomena-report[R/OL]. 2018. https://www.sandvine.com/2018-internet-phenomena-report.

SHIH L K, KARGER D R. Using urls and table layout for web classification tasks[J/OL]. Proceedings of the 13th conference on World Wide Web - WWW '04, 2004:193. http://portal.acm.org/citation.cfm?doid=988672.988699. DOI: 10.1145/988672.988699.

SONG J, YANG Y, HUANG Z. Multiple feature hashing for real-time large scale near-duplicate video retrieval[J/OL]. Proceedings of the 19th …, 2011:423-432. http://dl.acm.org/citation.cfm?id=2072354. DOI: 10.1145/2072298.2072354.

SPRING N T, WETHERALL D. A protocol-independent technique for eliminating redundant network traffic[J/OL]. Sigcomm, 2000, 30(4):87-95. DOI: 10.1145/347057.347408.

STORE A R C, ALGORITHM B R. Advanced Prediction-Based System for Cloud Bandwidth and Cost Reduction[J]. 2013, 8491:224-226.

TAN G, ZHANG P, LIU Q, et al. Adaptive Malicious URL Detection: Learning in the Presence of Concept Drifts[J/OL]. Proceedings - 17th IEEE International Conference on Trust, Security and Privacy in Computing and Communications and 12th IEEE International Conference on Big Data Science and Engineering, Trustcom/BigDataSE 2018, 2018:737-743. DOI: 10.1109/TrustCom/BigDataSE.2018.00107.

TANG P, WANG Z. Classification of Internet Video Traffic Using[J]. 2017(978).

VASTEL A, INRIA I, LAPERDRIX P, et al. Fp-Scanner : The Privacy Implications of Browser Fingerprint Inconsistencies[J]. USENIX Security, 2018.

WANG J, ZHAO P, HOI S C, et al. Online feature selection and its applications[J/OL]. IEEE Transactions on Knowledge and Data Engineering, 2014, 26(3):698-710. DOI: 10.1109/TKDE.2013.32.

WANG J, LI G, DENG D, et al. Two birds with one stone: An efficient hierarchical framework for top-k and threshold-based string similarity search[J/OL]. Proceedings - International Conference on Data Engineering, 2015, 2015-May:519-530. DOI: 10.1109/ICDE.2015.7113311.

WEI J, JIANG H, ZHOU K, et al. MAD2 : A Scalable High-Throughput Exact Deduplication Approach for Network Backup Services[J].

WINTER C, SCHNEIDER M, YANNIKOS Y. F2S2: Fast forensic similarity search through indexing piecewise hash signatures[J/OL]. Digital Investigation, 2013, 10(4):361-371. http://dx.doi.org/10.1016/j.diin.2013.08.003.

WU K L, YU P S, WOLF J L, et al. Segment-Based Proxy Caching of Multimedia Streams[J].

XIAO W, XUE J, MIAO Y, et al. Tux2: Distributed Graph Computation for Machine Learning[J/OL]. Nsdi, 2017:669-682. https://www.usenix.org/conference/nsdi17/technical-sessions/presentation/xiao.

YU L, LIU H. Efficient Feature Selection via Analysis of Relevance and Redundancy[J/OL]. J. Mach. Learn. Res., 2004, 5:1205-1224. http://dl.acm.org/citation.cfm?id=1005332.1044700.

YU L, SAPRA K, SHEN H, et al. Cooperative End-to-End Tra ffi c Redundancy Elimination for Reducing Cloud Bandwidth Cost[J].

ZHANG B, JIN X, RATNASAMY S, et al. AWStream[J/OL]. Proceedings of the 2018 Conference of the ACM Special Interest Group on Data Communication - SIGCOMM '18, 2018:236-252. http://dl.acm.org/citation.cfm?doid=3230543.3230554. DOI: 10.1145/3230543.3230554.

ZHANG H, ANANTHANARAYANAN G, BODIK P, et al. Live video analytics at scale with approximation and delay-tolerance[J/OL]. Proceedings of the 14th USENIX Conference on Networked Systems Design and Implementation, 2017:377-392. https://dl.acm.org/citation.cfm?id=3154661.

ZOHAR E, CIDON I, MOKRYN O. PACK: Prediction-based cloud bandwidth and cost reduction system[J/OL]. IEEE/ACM Transactions on Networking, 2014, 22(1):39-51. DOI: 10.1109/TNET.2013.2240010.

作者简历及攻读学位期间发表的学术论文与研究成果

作者简历

本文作者

陈冠林，安徽省合肥市人，中国科学院信息工程研究所硕士研究生。

致　谢

时间飞逝，很快就到了硕士毕业的时候了。借此论文完成的机会，在此向多年来给我关心和帮组的老师、同学、家人和朋友们表示衷心的感谢！

首先，要感谢我的父母，父母为我付出了毕生的精力，将我抚养成人。在我最困难的时候帮助我，虽然他们都不是科研人员，也没有很高的学术水平。但无论时科研上的烦心事，还是生活上的琐事，都会认真倾听，帮我解决问题。即使解决不了也会开导我。

接着向我敬爱的小导师——郑超老师表达我的感谢之情。郑超老师严谨认真、学识渊博、思维敏捷且富有激情。在我硕士在读期间，郑超老师对我的研究生课程学习、课题研究等方面给出了很多的指导和帮助，让我开阔了思路，培养了独立进行研究和工程设计的思维和基本素养。

其次，我要感谢组长和我的导师刘庆云老师在研究生阶段对我的帮助。刘老师视野开阔、知识渊博，并且十分关心学生的成长。每次都能发现学生工作、学习中的问题，并提出十分有指导意义的意见。

感谢第二研究室处理架构组的周舟老师、杨嵘老师、朱宇佳老师、李佳老师、李钊老师、杨威老师等。在实验室里老师们对每一个学生都提供了真心的帮助，在科研学习上，能得到他们的帮助，让我受益颇多。我也会学习各位老师对科研锐意进取、对生活充满热情的学习生活态度，在今后的工作生活中继续进步。

感谢在实验室给了我很大帮助的师兄师姐们：陆秋文、张曦、谭国林、黄彩云，他们在我最迷茫无助的时候给了我很多的帮助。特别是陆秋文师兄，在工作压力很大的情况下，对实验室的每个师弟师妹都给与了很多帮助，看到的有价值的知识、文章也第一时间分享给师弟师妹们，给我树立了优秀的榜样。感谢组里的崔一鸣、罗成志、李白杨师弟，邹雨婷、柳幼婷、周钊宇、王钰、尚晶晶、马小青师妹，在日常学习和生活中的陪伴。

还更要感谢同一届的李杰、贺文梁、张中一、杨兴东、张晓欧、田湘、钟友兵同学，在三年研究生生活中他们是陪伴我最多的人，虽然大家的研究方向各不相同，但一直在一起拼搏、一起奋斗，总找机会一起分享学习上的经验和成果。

陈冠林

2019 年 3 月 14 日写于国科大